

MÜŞTERİ TABANI ANALİZİ VE CHURN TAHMİNİ

*Modern Olasılık Modellerinden Derin Öğrenme
Yaklaşımlarına Akademik Sentez*

KAPSAMLI DERS NOTLARI

Birleşik Ders Notları

1. MÜŞTERİ STOKASTİK PARETO/NBD

DAVRANIŞININ MODELLENMESİ:

Counting Your Customers: Who-Are They and What Will They Do Next?

1. Giriş: Müşteri Davranışının Sürekli Zamanlı Stokastik Ontolojisi ve Heuristiklerin Çöküşü

İş dünyasında, özellikle perakende, bankacılık, havayolu veya katalog taşımacılığı gibi müşterilerin firmayla diledikleri an (sürekli bir zaman çizgisinde) etkileşime girebildiği "sözleşmesiz" (non-contractual) ortamlarda, bir müşterinin "aktif" mi yoksa "terk etmiş" (inactive/dead) mi olduğunu bilmek milyar dolarlık bir sorundur. Klasik pazarlama yöneticileri, bu sorunu çözmek için sezgisel (heuristic) yöntemlere başvururlar; örneğin "son 6 ayda alışveriş yapmayan müşteri ölüdür" derler. Ancak bu deterministik ve statik varsayım, insan davranışının ardındaki (mu)azzam stokastik (rastlantısal) doğayı, Seyreklik (Sparsity) problemini ve Ortalamaya Dönüş (Regression to the Mean) fenomenini tamamen göz ardı eder. Müşteri davranışı saat gibi işleyen mekanik bir süreç değildir; karmaşık olasılık dağılımlarının bir sonucudur. Eğer bir müşteri doğası gereği zaten çok nadir alışveriş yapıyorsa (örneğin 2 yılda bir), 6 aylık bir sessizlik onun kuru(mu) terk ettiği anlamına gelmez. Tam tersine, her hafta alışveriş yapan bir müşteri 2 ay sessiz kalırsa, bu kişinin sistemi terk etmiş olma olasılığı devasadır. Sezgisel kurallar (heuristics) bu asimetriyi asla yakalayamaz. İşte bu felsefi ve matematiksel tikanıklığı aşmak için David Schmittlein, Donald Morrison ve Richard Colombo, 1987 yılında pazarlama analitiğinde bir devrim yaratan Pareto/NBD (Negative Binomial Distribution) modelini inşa ettiler. Makalenin doğuş noktası, dünyanın en büyük finans kuruluşlarından biri olan Merrill Lynch'in perakende aracılık (brokerage) biriminin yaşadığı krizdir. Yüz binlerce müşterisi olan kurum, kimin aktif kimin inaktif olduğunu bilemediği için gelecek yılın komisyon gelirlerini ve büyüme oranlarını tahmin edememektedir. Müşteri

memnuniyetsiz kaldığında kuru(\mu) arayıp "hesabımı kapatın" demez, hisselerini sessizce başka kuruma taşır (sessiz yıpranma). Pareto/NBD modeli, insan davranışını sürekli bir zaman denizinde, kesin sınırlarla ayrılmamış rastgele karar anlarında değerlendiren ve bu "sessiz ölümü" tespit eden ilk gerçekçi jeneratif modeldir.

2. Bireysel Seviye: Poisson Süreci ve Üstel (Exponential) Yaşam Ömrü

Modelin mimarisi, birey seviyesinde iki temel varsayımla başlar. Birinci varsayım, satın alma eylemlerinin bir Poisson süreci izlediğidir. Müşteri "hayatta" (aktif) olduğu sürece, belirli bir ortalama işlem hızıyla (λ), λ satın alma yapar. Poisson süreci, sürekli zaman alanında rastgele gerçekleşen olayları modellemek için kullanılan, "hafızasızlık" (memoryless) özelliğine sahip eşsiz bir matematiksel yapıdır. Hafızasızlık, bir müşterinin bir sonraki satın alma işlemini ne zaman yapacağını, bir önceki işlemi ne zaman yaptığını bağlı olmaması demektir. Bu durum, olaylar arasındaki sürenin Üstel (Exponential) dağıldığı anlamına gelir. Birey, her an alışveriş yapma potansiyeline sahiptir ve bu potansiyel λ parametresiyle kontrol edilir. İkinci varsayım, yaşam ömrünün, yani "terk etme" anının da Üstel dağılımla modellenmesidir. Sözleşmesiz bir dünyada ölüm anı (τ), τ gözlemlenemeyen (unobserved) bir değişkendir. Model, her müşterinin kendine has bir "ölüm hızı" (μ), μ olduğunu ve bu hızla kontrol edilen Üstel bir yaşam ömrüne sahip olduğunu varsayar. Bu süreç de hafızasızdır; müşteri ne kadar uzun süredir hayattaysa, bir sonraki an ölme ihtimali ne artar ne azalır, her an μ hızıyla ölüm riski altındadır.

3. Popülasyon Heterojenliği: Gamma Dağılımlarının İhtişamı

Eğer dünyadaki tüm müşterilerin satın alma hızı (λ) ve ölüm hızı (μ) aynı olsaydı, işimiz çok kolay olurdu. Ancak gerçeklik, korkunç bir heterojenlik (farklılık) içerir. Pareto/NBD modeli bu μ çeşitliliği kontrol altına almak için Bayesyen yaklaşımın en güçlü silahı olan Gamma dağılımını kullanır. Üçüncü ve dördüncü varsayımlara göre, popülasyondaki λ değerleri (r , α) parametrelerine sahip bir Gamma dağılımından, μ değerleri ise (s , β) parametrelerine sahip ayrı bir Gamma dağılımından çekilmiştir. Neden Gamma dağılımı? İstatistiksel kuramda Gamma dağılımı, Poisson ve Üstel dağılımların "eşlenik önseli"

(conjugate prior) olarak bilinir. Yani Gamma önseli (prior) ile Poisson'u birleştirdiğinizde, ortaya analitik olarak entegre edilebilir kapalı formlu bir dağılım olan Negatif Binom Dağılımı (NBD) çıkar. Aynı şekilde, Gamma önseli ile Üstel dağılımı birleştirdiğinizde, ikinci türden Pareto dağılımı elde edilir. Bu matematiksel kapanış özelliği, sonsuz sayıdaki olası λ ve μ kombinasyonunu sadece dört adet küresel parametre (r , α , s , β) ile devasa bir veritabanı üzerinde modellememize imkan tanır. Beşinci varsayım ise λ ve μ 'nün birbirinden bağımsız olduğudur. Yoğun işlem yapan birinin kuru(μ) terk etme ihtimali, nadir işlem yapana göre istatistiksel olarak bir korelasyona sahip değildir, model bu iki mekanizmayı ayrı ayrı çalıştırır.

4. Hayatta Kalma Olasılığı: P(Alive) ve Gauss Hipergeometrik Fonksiyonu

Modelin en can alıcı sorusu şudur: Elimizde bir müşterinin işlem geçmişi var (X : işlem sayısı, t : son işlemin zamanı, T : müşterinin bizimle olduğu toplam süre). Bu bilgilere dayanarak, bu müşterinin ' T ' anında hala aktif (hayatta) olma olasılığı nedir? Denklem 10'da makale, bu olasılığı bulmak için, müşterinin hayatta kalma olasılığını tüm olası λ ve μ kombinasyonları (joint distribution) üzerinden entegre eder. Bayes teoremi kullanılarak güncellenmiş (posterior) dağılım hesaplanır. Ancak bu integral alma süreci, basit cebirsel fonksiyonlarla çözülemez. Diferansiyel denklemlerin en derin dehlizlerinden gelen Gauss Hipergeometrik Fonksiyonu (${}_2F_1$) bu noktada sahneye çıkar (Denklem 11, 12 ve 13). $\alpha > \beta$, $\alpha < \beta$ ve $\alpha = \beta$ durumları için ayrı ayrı türetilen bu denklem, sonsuz Taylor serilerinin yakınsamasına dayanan olağanüstü karmaşık bir matematiksel yapıdır. Sürekli zaman analizlerinde (continuous-time hazard models), bağımsız ölüm ve satın alma hızlarını Gamma dağılımı üzerinden entegre etmeye çalıştığınızda hipergeometrik fonksiyonlardan kaçış yoktur. Bu fonksiyon, $T-t$ (sessizlik süresi) arttıkça P(Alive) olasılığının nasıl non-lineer (doğrusal olmayan) bir şekilde çöktüğünü istatistiksel bir kesinlikle belirler.

5. Tablo 1 ve 2 Paradoksu: P(Alive) ile Gelecek Beklentisi Arasındaki Savaş

Makaledeki sayısal analizler (Tablo 1 ve 2), deterministik yaklaşımların ne kadar tehlikeli olduğunu gösteren (μ)azzam bir paradoks ortaya koyar. İki müşteri düşünelim: A

müşterisi 2 yılda 4 alışveriş yapmış, B müşterisi ise 2 yılda hiç alışveriş yapmamıştır (0 işlem). İkisinin de son etkileşiminden bu yana 1 yıl geçmiştir ($T=2$, $t=1$). Sezgilere göre 4 alışveriş yapan daha değerlidir değil mi? Hayır! Makale ispatlar ki, B müşterisinin (0 işlem) hayatta olma ihtimali ($P(\text{Alive}) = 0.36$), A müşterisinin (4 işlem) hayatta olma ihtimaliyle (0.36) tamamen aynıdır! Çünkü 4 işlem yapıp birden sessizleşen biri büyük ihtimalle "ölmüştür", oysa hiç işlem yapmayan biri zaten doğası gereği "düşük frekanslı"dır, yani onun sessizliği ölmesinden değil doğasından kaynaklanır. Daha da sarsıcı olanı: İkisinin de hayatta olma ihtimali aynı olmasına rağmen, "Gelecek 2 yılda kaç işlem yapacaklar?" ($E[X^*]$) sorusunun cevabı bambaşkadır. A müşterisinden 0.99 işlem beklenirken, B müşterisinden sadece 0.09 işlem beklenir (10 kat fark). İşte Bayesyen Ortalamaya Dönüş prensibi budur. Ölüm ihtimali ile gelecek satınalma potansiyeli aynı şey değildir ve sezgiler bu ikisini asla birbirinden ayıramaz.

6. Parametre Tahmini: MLE, Momentler Yöntemi ve Yönetici Sezgileri

Peki devasa bir veritabanı için bu (r , α , s , β) parametrelerini nasıl bulacağız? Makale üç farklı yol önerir:

1. Maksimum Olabilirlik (MLE): En kesin olandır, ancak hipergeometrik fonksiyonların bilgisayar işlemcilerinde binlerce kez türevinin alınması gerektiği için dönemin (1987) hesaplama gücü açısından son derece maliyetlidir.

2. Momentler Yöntemi (Fitting Observed Moments): Makale (Denklem 24-29), çok daha zekice bir yaklaşım geliştirir. Bireylerin gelecekte yapacağı işlemlerin *beklenen değeri* ve *varyansı* üzerinden, gerçek verideki (ampirik) ortalama ve varyansları eşitleyerek (fitting) denklemler çözer. Yani verinin 1. ve 2. momentlerini (ortalama ve varyans) kullanarak iteratif olarak r , α ve s , β oranlarına ulaşır. Bu, karmaşık integralleri çözmeden sisteme yaklaşmanın en analitik yoludur.

3. Yönetici Sezgileri (Management Judgments): Yeni kurulan bir şirket veya yeni bir ürün lansmanı düşünün. Elinizde hiç veri yok! Model, yöneticilerin "Müşterilerimizin ne kadarı yılda 2'den az alışveriş yapar?" gibi subjektif pazar araştırması sezgilerini Bayesyen Prior (önsel dağılım) olarak alıp modeli başlatmaya imkan tanır.

7. Sonuç ve Yönetmel Çıkarımlar

Pareto/NBD makalesinin, salt bir akademik yayın olmanın çok ötesine geçerek müşteri tabanı analitiğinde "Altın Standart" (Gold Standard) olarak kabul edilmesinin temel nedeni, yöneticileri deterministik yanılgılardan ve kaba önyargılardan kurtarmasıdır. Kurumsal kaynak planlaması ve sadakat programları tasarlanırken şu çıkarımlar göz önünde bulundurulmalıdır: Birincisi, Sessizlik Ölüm Demek Değildir (Seyreklik Doğası): Müşterilerin davranışlarındaki boşluklar, onların kuru(\mu) terk ettiğı anlamına gelmez. Satın alma hızı (λ) doğası gereğı düşük olan müşteriler (örneğin lüks tüketim veya perakende aracılık), çok uzun süreler boyunca işlem yapmasalar bile hala aktif (alive) olabilirler. Sezgisel kurallar (heuristics) bu değerli kitleyi "ölü" zannederek geri kazanım kampanyalarından dışlar. Pareto/NBD, P(Alive) metriğıyle bu gizli değeri kurtarır. İkincisi, Kişiselleştirilmiş İskonto ve Paradoks: Yüksek işlem sıklığına (High Frequency) sahip ancak yenilik (Recency) değeri düşük olan (uzun süredir işlem yapmayan) bir müşteri, düşük sıklığa sahip ama yine uzun süredir işlem yapmayan bir müşteriden çok daha yüksek ihtimalle kuru(\mu) terk etmiştir. Bu paradoksal gerçeğı, makaledeki sayısal analizler ispatlamıştır. Şirketler, pazarlama harcamalarını ve promosyon bütçelerini dağıtırken, P(Alive) oranlarını ve Bayesyen koşullu beklentileri birincil filtre olarak kullanmalıdır. Üçüncüsü, Matematiksel Modellerin Rekabet Avantajı: Gamma dağılımları, Üstel bozulmalar ve Gauss Hipergeometrik fonksiyonlarıyla örölü bu karmaşık altyapı, aslında tek bir amaca hizmet eder: İnsan davranışının o kaotik ve görünmez doğasını, bilimin ışığında ölçülebilir bir yatırım aracına dönüştürmek. Geleceğın sadakat programları, geçmişte "kimin daha çok aldığına" göre değil, gelecekte "kimin olasılsal olarak hala bizimle olduğuna" göre tasarlanacaktır. Pareto/NBD, pazarlama departmanlarının karanlıkta el yordamıyla yürümesini engelleyen devasa bir ışıktır.

2. YAŞAM ÇÖZÜMLEMESİ VE COX ORANTISAL TEHLİKE: FİNANS SEKTÖRÜNDE CHURN

Customer attrition analysis for financial services using proportional hazard models

1. Giriş: Müşteri Ölümünün Felsefesi ve CRM'in Ekonomik Çekirdeği

Modern işletme çağında pazar doygunluğunun ve hiper-rekabetin zirveye ulaşması, kurumları temel bir varoluşsal gerçeğe yöneltmiştir: Şirketlerin sahip olduğu en değerli varlık, yeni kazanılacak meçhul kitleler değil, halihazırda sistemde bulunan mevcut müşteri tabanıdır. Müşteri İlişkileri Yönetimi (CRM), bu aydınlanmanın sonucunda doğmuştur. Finansal hizmetler sektöründe (bankacılık ve sigortacılık), deregülasyonlar ve kıyasıya Avrupa entegrasyonu, müşterilerin geçiş maliyetlerini (switching costs) dramatik şekilde düşürmüştür. Müşteri kaybı (customer attrition veya churn), artık sadece satışların azalması anlamına gelmez; aynı zamanda yeni müşteri kazanmanın getirdiği o devasa 5-6 katlık ekstra maliyetin yüklenilmesi, ağızdan ağıza (word-of-mouth) yayılan organik büyüme motorunun durması ve veri tabanında biriken paha biçilemez müşteri istihbaratının sonsuza dek silinmesi demektir. Makale, klasik müşteri memnuniyeti anketlerinin (survey data) içerdiği devasa "seçim yanlılığına" (selection bias) karşı felsefi bir duruş sergiler. Çoğu şirket müşteri sadakatini anketlerle ölçmeye çalışır, ancak insanlar her zaman söylediklerini yapmazlar. Eylemler, sözlerden çok daha gürültülü konuşur. Bu nedenle Dirk Van den Poel ve Bart Larivière, anketleri bir kenara bırakıp Avrupa'lı dev bir finans kuruluşunun Veri Ambarı'nın (Data Warehouse) derinliklerine inerek, müşterilerin tamamen tarafsız, gerçek gözlemsel verileri (observational data) üzerinden "eyleme dökülmüş" davranışları analiz etmiştir. Bu analiz, deterministik ve statik müşteri tutma (retention) yaklaşımlarına karşı açılmış matematiksel bir savaştır. Klasik yaklaşımlar (örneğin sıradan Lojistik Regresyon modelleri), zamanı dondurulmuş bir fotoğraf karesi olarak ele alır ve müşterilerin davranışlarını statik bir noktada ölçerek "terk edecek mi, etmeyecek mi?" (0 veya 1) gibi sığ bir ikili sınıflandırmaya indirger. Ancak insan hayatı ve dolayısıyla müşteri davranışı,

zamanın acımasız ve sürekli akışı içinde şekillenir. Bir müşterinin maaşının artması, makroekonomik krizler veya bankanın bir başka bankayla birleşmesi (merger) gibi olaylar "zamanla değişen" (time-varying) dinamiklerdir. Bu makale, tıp biliminde kanser hastalarının yaşam sürelerini analiz etmek için doğ(\mu)ş olan Yaşam Çözümlemesi (Survival Analysis) ve Cox Orantısal Tehlike (Proportional Hazard) modellerini pazarlama biliminin kalbine yerleştirerek, müşteri ölümünün (churn) anlık riskini ve zamanlamasını stokastik bir düzlemde modeller.

2. Yaşam Çözümlemesi (Survival Analysis): Stokastik Zamanın Matematiği

Yaşam Çözümlemesi (Survival Analysis), olayların (events) meydana gelme zamanını ve bu zamanın hangi dışsal faktörlere bağlı olduğunu modelleyen probabilistik (olasılıksal) bir istatistik dalıdır. Pazarlama bağlamında "olay", müşterinin bankadaki tüm hesaplarını kapatarak kuru(\mu) kalıcı olarak terk etmesidir. Bu modellemede zaman (T), sıradan bir sayaç değil, üzerinde bir olasılık dağılımı tanımlanmış sürekli bir rastlantısal değişkendir. Klasik istatistikteki tüm deterministik kurallar burada yıkılır ve yerine şu dört temel probabilistik sütun inşa edilir: Birincisi, zamanın Olasılık Yoğunluk Fonksiyonu (Probability Density Function - p.d.f.), yani $f(t)$ 'dir. Bu fonksiyon, müşterinin tam olarak " t " anında (ne bir saniye önce, ne bir saniye sonra) sistemi terk etme ihtimalini ifade eder. Ancak sürekli zaman matematiğinde tek bir "nokta"nın olasılığı sıfırdır, bu yüzden entegral alınması gerekir. İkincisi, Birikimli Dağılım Fonksiyonu (Cumulative Distribution Function - c.d.f.), yani $F(t)$ 'dir. (Denklem 1), müşterinin ' t ' anına kadar kuru(\mu) terk etmiş olma olasılığını gösterir. $F(t) = \Pr\{T \leq t\}$ Üçüncüsü ve felsefi olarak en kritiği olan Sağkalım Fonksiyonu (Survivor Function), yani $S(t)$ 'dir (Denklem 2). Bu fonksiyon, müşterinin ' t ' anından daha uzun süre ($T > t$) hayatta kalma (müşteri olarak devam etme) ihtimalini verir. $S(t) = \Pr\{T > t\} = 1 - F(t)$ Türevi alındığında $f(t)$ fonksiyonunu verir. Dördüncüsü ve modelin kalbi olan Tehlike Fonksiyonu (Hazard Function), $h(t)$ 'dir (Denklem 4). Tehlike fonksiyonu, müşterinin ' t ' anına kadar hayatta kaldığı bilindiği durumda (koşullu olasılık), tam o saniyede/anda (t ile $t + \Delta t$ arasında) ölme (churn olma) riskinin anlık türevidir. $h(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr\{t \leq T < t + \Delta t \mid T \geq t\}}{\Delta t}$ Sağkalım fonksiyonu (Survivor) kümülatif birikimi temsil ederken, Tehlike fonksiyonu (Hazard) hız göstergesindeki ibrenin anlık olarak gösterdiği hızı (risk ivmesini) temsil eder.

3. Cox Orantısal Tehlike (Proportional Hazard) Modeli ve Zamanla Değişen Değişkenler

Sıradan yaşam çözümlmeleri sadece zamanı hesaba katar. Ancak banka yöneticileri için asıl soru şudur: Müşterinin riskini (Hazard) belirleyen faktörler (kovaryatlar) nelerdir? İşte burada Sir David Cox tarafından tıp dünyasına armağan edilen, istatistik biliminin en sağlam (robust) yapılarından biri olan Cox Proportional Hazard modeli devreye girer. Bu model, tehlike fonksiyonunun iki bağımsız parçadan oluştuğunu varsayar: Birincisi, zamana bağlı temel tehlike (baseline hazard) fonksiyonu; ikincisi ise bireyin özelliklerine (kovaryatlarına) bağlı olan ve zamanla üstel olarak çarpılan risk çarpanı. Modelin adındaki "Orantısal" (Proportional) kelimesi, temel bir varsayımdan gelir: Herhangi iki bireyin tehlike (hazard) oranları, zaman boyunca birbirine sabit bir orantıdadır. Ancak, makalenin literatüre yaptığı en devasa katkı tam da bu kuralı yıkan Zamanla Değişen Kovaryatların (Time-Varying Covariates) modele dahil edilmesidir! Bir müşteri bugün sadece bir vadesiz hesabı varken, 5 yıl sonra kredi kartı alabilir. Değişkenler zamanla değer değiştirdiği an, "sabit orantısallık" kuralı kasıtlı olarak esnetilir. Müşteri evrildikçe, onun taşıdığı anlık "Tehlike" (Hazard) seviyesi dinamik olarak yeniden hesaplanır. Statik lojistik regresyonun (ki o sadece zamanın bir anındaki fotoğrafı çeker) asla yapamayacağı dinamik video kaydını Cox modeli gerçekleştirir.

4. Çoklu Bağlantı (Multicollinearity), Veri Madenciliği ve Sansürlü Veri

Araştırmacılar, 47.157 müşterilik devasa bir rastgele veri ambarı örneği kullanmıştır. Modelin sağlamlığını (robustness) test etmek için makine öğrenmesinin en ciddi sorunlarından ikisine meydan oku(\mu)şlardır. Birincisi, Eksik Veri (Missing Data) ve Karar Ağacı Ataması (Tree Imputation): Sosyoekonomik durum gibi verilerdeki eksiklikler, göz ardı edilip silinmek (listwise deletion) yerine, diğer değişkenlerin gücünü kullanan Karar Ağaçları algoritmalarıyla tahmin edilip atanmıştır (imputation). İkincisi, Çoklu Bağlantı (Multicollinearity) ve Zaman Serisi İçi Korelasyon: "Maaş" ile "Kredi Kartı Limiti" gibi değişkenler genelde birbiriyle yüksek korelasyonludur ve regresyon modellerinde standart hataları patlatarak parametreleri güvenilmez kılar. Araştırmacılar değişkenleri modele sırayla sok(\mu)ş ve korelasyon kesme noktalarını (cut-off) 0.20'den 0.80'e kadar zorlayarak parametre kararlılığını test etmiştir. Makale, 0.40'lık bir korelasyon eşliğinin opti(\mu)m olduğunu devasa bir istatistiksel tabloyla ispatlar. Üçüncüsü, Sansürlü Gözlemler (Censored Observations): Analizin bittiği tarih itibarıyla bankada hala aktif olan

müşteriler vardır. Klasik modeller bu verileri çöpe atarken, Yaşam Çözümlemesi sağdan sansürlü (right-censored) olarak bilinen bu verileri "en azından o güne kadar hayatta kalmış olmaları" bilgisi üzerinden ihtimaller havuzuna (\mu)azzam bir zarafetle katar.

5. İkincil Banka (Secondary Bank) Sendro(\mu) ve Eğitim Paradoksu

Modelin sonuçları incelendiğinde, bankanın piyasadaki konu(\mu) analizleri derinden etkilemiştir. İncelenen Avrupa'lı finans kuru(\mu), müşterilerin gözünde genellikle "Birinci/Ana Banka" değil, "İkincil Banka" (Secondary Banking Institute) konu(\mu)ndadır. Çoğu müşteri burayı sadece yedek bir tasarruf hesabı olarak kullanmaktadır. Eğitim düzeyi ile churn arasında kurulan ilişki bu yüzden hayati bir öneme sahiptir. Makale, yüksek eğitilmiş müşterilerin churn olma oranının %8.2 daha düşük olduğunu bul(\mu)ştur! Neden mi? Çünkü yüksek eğitilmiş müşteriler, birden fazla bankayla ((\mu)lti-bank) çalışmanın finansal avantajlarını kavramış olan rasyonel karar vericilerdir. Onlar, ikincil bankalarını bilinçli olarak seçtikleri için "rastgele" kararlarla bankayı terk etme eğilimleri çok daha düşüktür. Eğitim düzeyi, bankanın piyasadaki "ikincil" konu(\mu)nu bir dezavantajdan, kalıcı bir avantaja dönüştürmüştür.

6. Kaplan-Meier Sağkalım Eğrisi ve Kritik Yaşam Döngüsü

Makalenin temel ampirik bulgularından biri, müşterilerin banka ile olan yolculuğunu gösteren Kaplan-Meier Sağkalım Eğrisi (Survival Curve)'dir (Şekil 2). Kaplan-Meier, her ölüm anında hayatta kalma olasılığını yeniden çarpan non-parametrik bir eğridir. Şekil 2, bankacılık sektöründeki acımasız bir gerçeği kanıtlar: Müşterinin yaşam döngüsünde iki devasa "kritik" tehlike periyodu vardır. Müşteri ilk kazanıldığında (ilk 5-7 yıl) eğri inanılmaz bir hızla aşağı düşer. Bu, adaptasyon sürecini atlatamayan müşterilerin toplu katliamıdır. Eğer müşteri 7. yılı sağ atlatırsa, eğri bir platoya (yatay düzleme) oturur ve 15-20 yıl boyunca (\mu)azzam bir sadakat gösterir. Ancak 20. yıldan sonra, emeklilik veya makroekonomik döngüler sebebiyle sağkalım eğrisi tekrar aşağı doğru acımasızca çökmeye başlar.

7. Sonuç ve Yönetmel Çıkarımlar

Bu çalışma, müşteri veritabanlarının derinliklerinde yatan ölüm-kalım felsefesini Cox Orantısal Tehlike modeliyle gün yüzüne çıkarmıştır. Bu istatistiksel ispatlardan yöneticilerin alması gereken stratejik dersler şunlardır: Birincisi, Çapraz Satışın (Cross-Selling) Paradoksu: Varsayımların aksine, müşterinin sahip olduğu spesifik ürün türleri, müşteriyi elde tutmada anlamsız kalmıştır. Önemli olan "hangi" ürüne sahip olduğu değil, "kaç farklı" ürüne sahip olduğudur (Total product ownership). Hele ki "İkincil Banka" konu(\mu)nda olan bir kurumda, tek bir ürün daha satmak, müşterinin terk etme (churn) ihtimalini anında %99.9 oranında düşürmektedir! Finansal kurumlar spesifik ürün dayatmak yerine, portföyü genişleten agresif çapraz satış ve üst satış kampanyaları kurgulamalıdır. İkincisi, İki Alışveriş Arası Süre (Interpurchase Time) Sinyalleri: Analiz, müşterinin iki finansal işlemi arasındaki sürenin uzaması halinde (seyreklik), churn tehlikesinin her yıl için %4.9 arttığını ispatlamıştır. Sessizlik altın değildir; sessizlik, rakiplerle flört etmenin ayak sesidir. Kurumlar müşterilerini inaktif bırakmamak için proaktif mikro-etkileşimler tasarlamak zorundadır. Üçüncüsü, Makro Çevre, Şirket Birleşmeleri (Merger) ve Demografi: Model, gayrisafi milli hasılanın (GNP) artmasının paradoksal olarak müşteri sadakatini düşürdüğünü (daha fazla churn yarattığını) ortaya koy(\mu)ştur. Zenginleşen müşteri, alternatif arama lüksüne sahip olur. Cinsiyet bağlamında ise erkeklerin kadınlara göre bankayı terk etme olasılığının %141 daha yüksek olduğu görülmüştür. Öte yandan, bankanın geçirdiği "Şirket Birleşmesi" (Merger) sanılanın aksine yıkıcı olmamış, yeni bankanın gücünü artırdığı algısıyla müşterileri elde tutmada pozitif/nötr etki yaratmıştır. Özetle, Müşteri İlişkileri Yönetimi (CRM) öznel anketlere ve sığ "son 6 ay" kurallarına terk edilemez. Veriyi zamanla değişen (time-varying) bir canlı organizma olarak okuyan şirketler, rakiplerinin neden müşteri kaybettiğini anlamadıkları bir piyasada, kimin ne zaman kuru(\mu) terk edeceğini aylar öncesinden bilecek ve önlemini alacaktır.

3. KESİKLİ ZAMAN VE SÖZLEŞMESİZ MODELLER: BG/BB

Customer-Base Analysis in a Discrete-Time Noncontractual Setting

1. Giriş: İnsan Davranışının Stokastik Ontolojisi ve Determinizmin Çöküşü

İnsan davranışını, özellikle de tüketici veya bağışçı eylemlerini matematiksel bir zemine oturtma çabası, on yıllardır süregelen ampirik ve teorik bir meydan okumadır. Klasik deterministik yaklaşımlar, bireylerin gelecekteki davranışlarını geçmiş eylemlerinin doğrusal bir uzantısı olarak görme eğilimindedir. Ancak bu vizyon, insan doğasının içerdiği rastlantısallığı (stokastik doğayı) göz ardı ettiği için çoğu zaman ağır tahmin hatalarıyla sonuçlanır. Bu noktada "Ortalamaya Dönüş" (Regression to the Mean) kavramı devreye girer. Bir birey, belirli bir zaman diliminde tesadüfi bir şekilde ortalamasının çok üzerinde bir işlem (satın alma, bağış yapma vb.) gerçekleştirebilir. Eğer modelimiz salt deterministik ise, bu anomaliyi kalıcı bir eğilim olarak kodlayacak ve geleceği devasa bir pozitif hatayla tahmin edecektir. Oysa istatistiksel gerçeklik bize, uç değerlerin zamanla genel popülasyon ortalamasına doğru geri çekileceğini söyler. Bu durum, özellikle veri setinin seyrek (sparsity) olduğu durumlarda daha da kritiktir. Bireyler her an, her saniye bağış yapmazlar; işlem anları son derece seyrektir ve bu "seyreklik" deterministik analizleri imkansız kılar. Müşteri sadakatini ve kalıcılığını modellemek için uzun zamandır endüstri standardı olarak kabul edilen Pareto/NBD (Negative Binomial Distribution) modeli, "sürekli zaman" (continuous-time) varsayımı üzerine inşa edilmiştir. Pareto/NBD, satın almaların herhangi bir an (t) içerisinde gerçekleşebileceğini varsayar ve bu nedenle satın alma sıklığını bir Poisson süreci ile tanımlar. Poisson süreci, hafızasızdır ve olaylar arasındaki sürenin üstel (exponential) dağıldığını söyler. Ancak, kilise katılımı, yıllık hayır kuru(\mu) bağışları veya periyodik akademik konferans katılımı gibi işlemler "ayrık zamanlı" (discrete-time) bir yapıya sahiptir. Bu tür durumlarda işlemler, zamanın sürekli bir akışında değil, belirli kesitlerinde (örneğin sadece her yılın Aralık ayında veya sadece Pazar sabahları) gerçekleşir. Sürekli zamana dayalı bir model olan Pareto/NBD, böylesine düzenli aralıklarla gerçekleşen işlemleri bir Poisson süreciyle açıklamaya çalıştığında

felaket derecesinde yanılır. Çünkü ortalaması çok düşük olan, örneğin yılda sadece bir kez bağış yapan bir kitleyi Poisson ile modellediğinizde, model bu düzensiz görünen düzenliliği anlayamaz ve kitlenin hızla "öldüğünü" veya aşırı inaktif olduğunu zanneder. Bu yetersizliğin üstesinden gelmek için, Fader, Hardie ve Shang tarafından geliştirilen ve Pareto/NBD'nin ayrık zamanlı doğrudan analogu olan BG/BB (Beta-Geometric/Beta-Bernoulli) modeli doğ(\mu)ştur. BG/BB modeli, insan davranışını sürekli bir zaman denizinde değil, kesin sınırlarla ayrılmış işlem fırsatları serisinde değerlendiren, felsefi ve matematiksel olarak çok daha sağlam bir zemine oturur. Bireylerin "yaşama" (aktif kalma) ve "satın alma" (işlem yapma) olasılıklarını ayrı ayrı ele alır ve bu parametrelerdeki gözlemlenemeyen heterojenliği (toplum içindeki çeşitliliği) Bayesyen bir çerçevede Beta dağılımları ile kusursuzca yakalar.

2. Modelin Davranışsal ve Matematiksel Varsayımları

BG/BB modelinin o(\mu)rgası, hem davranışsal hem de olasılıksal doğayı betimleyen altı temel varsayımdan oluşur. Bu varsayımlar, her bir bireyin zihnindeki karar alma sürecini matematiksel bir oyun olarak tanımlar. Varsayım 1 ve 2: Birey, firmayla veya kurumla olan ilişkisinde iki ana evreye sahiptir: Öncelikle belirli bir süre "hayattadır" (Alive - A) ve aktif bir müşteridir. Daha sonra bir noktada, sessiz sedasız kalıcı olarak inaktif hale gelir, yani "ölür" (Dead - D). Sözleşmesiz (non-contractual) ortamlarda bireyin kuru(\mu) arayıp "ben artık bağış yapmayacağım" dememesi duru(\mu), "sessiz yıpranma" (silent attrition) olarak adlandırılır. Birey hayatta olduğu sürece, karşılaştığı her bir ayrık işlem fırsatında (örneğin her yıl gönderilen bağış mektubu) sabit bir 'p' olasılığı ile işlem yapar. Bu süreç tam anlamıyla bir Bernoulli denemesidir (Bernoulli trial). Bir madeni paranın atılması gibi, sonuç ya 1 (işlem yapıldı) ya da 0'dır (işlem yapılmadı). Bireyin hayatta olduğu 'i' adet işlem fırsatı boyunca yapacağı toplam işlem sayısı bu nedenle bir Binom (Binomial) dağılımı izler. Binom dağılımı, n denemede k başarılı sonuç elde etme olasılığını, n'in k'lı kombinasyonunu kullanarak veren, ayrık olasılık kuramının en temel yapıtaşlarından biridir. Varsayım 3: "Hayatta" olan bir müşteri, her işlem fırsatının tam başlangıcında belirli bir '(\theta)' ((\theta)) olasılığı ile kalıcı olarak ölür. Bir bireyin ölmeden önce geçirdiği "hayatta kalma süresi", her adımda sabit bir ölüm olasılığıyla karşı karşıya kaldığı için Geometrik (Geometric) dağılım ile karakterize edilir. Geometrik dağılım, ilk başarıyı (veya bu bağlamda, ölüm adı verilen ilk başarısızlığı) elde edene kadar geçen başarısız denemelerin sayısını modelleyen ayrık bir olasılık dağılımıdır. Bu, hafızasızlık özelliğine sahip tek ayrık dağılımdır, yani bireyin şu ana kadar hayatta kalmış olması, bir sonraki

adımında ölme olasılığını ne artırır ne de azaltır; olasılık her zaman θ 'dır. Varsayım 4 ve 5: Bireyler homojen değildir; bir popülasyonda herkesin 'p' (satın alma olasılığı) ve θ (ölüm olasılığı) değeri aynı olamaz. Bayesyen istatistik biliminin en büyük gücü, bu gizli heterojenliği popülasyon geneline yayılmış bir olasılık dağılımı ile temsil etmesidir. Model, 'p' parametresinin popülasyon içindeki dağılımının (α, β) parametrelerine sahip bir Beta dağılımı ile, θ parametresinin ise (γ, δ) parametrelerine sahip ayrı bir Beta dağılımı ile modellendiğini varsayar. $f(p | \alpha, \beta) = \frac{p^{\alpha-1}(1-p)^{\beta-1}}{B(\alpha, \beta)}$, $0 \leq p \leq 1$, $\alpha, \beta > 0$ $f(\theta | \gamma, \delta) = \frac{\theta^{\gamma-1}(1-\theta)^{\delta-1}}{B(\gamma, \delta)}$, $0 \leq \theta \leq 1$, $\gamma, \delta > 0$ Neden özellikle Beta dağılımı seçilmiştir? İstatistiksel modellemede Beta dağılımı, Bernoulli ve Binom dağılımlarının "eşlenik önseli" (conjugate prior) olarak bilinir. Bir Bayesyen güncelleme yapıldığında, eğer önsel dağılımınız (prior) Beta ise ve veriniz Binom dağılıyorsa, sonsal dağılımınız (posterior) da kesin olarak bir Beta dağılımı olacaktır. Bu cebirsel kapanış (algebraic closure), analitik hesaplamaları (integral alma işlemlerini) inanılmaz derecede kolaylaştırır ve Excel gibi sıradan elektronik tablo yazılımlarında bile çözülebilen kapalı formulu denklemler üretir. Ayrıca Beta dağılımı $[0, 1]$ aralığında tanımlıdır ki bu, olasılık değerleri (p ve θ) için teorik olarak kusursuz bir uyumdur; alfa ve β parametrelerinin aldığı değerlere göre U-şekilli, çan eğrisi şeklinde, J-şekilli veya ters J-şekilli inanılmaz esnek formlar alabilir. Varsayım 6: Satın alma olasılığı 'p' ile ölüm olasılığı ' θ ', müşteriler arasında birbirinden bağımsız olarak değişir. Bu varsayım, analitik çözümleri mümkün kılan en kritik matematiksel köprüdür, ancak ilerleyen bölümlerde tartışacağımız üzere felsefi olarak tartışmaya en açık noktadır, zira çok sık işlem yapan birinin kuru(μ) terk etme ihtimali teorik olarak daha düşük olmalıdır.

3. Olabilirlik Fonksiyonunun (Likelihood Function) Devasa İnşası

Makinede öğrenmenin ve istatistiksel çıkarsamanın kalbi olan Olabilirlik (Likelihood) tahmini, elimizdeki gözlemlenen verinin, kurduğumuz model ve seçtiğimiz parametreler altında ortaya çıkma olasılığını maksimize etme sanatıdır. Lütfen sadece basit bir 10100 (Satın Alma, Bekleme, Satın Alma, Bekleme, Bekleme) satın alma geçmişini düşünün. Bireyin p ve θ değerlerini kesin olarak bildiğimizi varsayalım. Bu string'in gerçekleşme olasılığı nedir? Birey 3. işlemde satın alma yaptığına göre, en

azından o an için "hayattadır" (Alive). Ancak 4. ve 5. işlemlerde sessiz kalmıştır. Bu sessizlik üç farklı ontolojik senaryodan türeyebilir:

1. Senaryo (AAADD): Birey 3. işlemde hemen sonra (4. işlemin başında) kalıcı olarak ölmüş olabilir.

2. Senaryo (AAAAD): Birey 4. işlem fırsatında hayattaydı, sadece o gün şansı/kararı gereği satın almadı, fakat 5. işlem fırsatının hemen başında öldü.

3. Senaryo (AAAAA): Birey tüm bu süreç boyunca hayattaydı ve aktif bir müşteriydi, sadece 4. ve 5. fırsatlarda '1-p' olasılığı devreye girdi ve işlem yapmamayı tercih etti.

Matematiksel olarak bu durum her senaryonun olasılıklarının toplamıyla ifade edilir. Makalede (Denklem 3) bu olağanüstü titizlikle şöyle yazılmıştır: $f(10100 \mid p, \theta) = f(10100 \mid p, AAADD) P(AAADD \mid \theta) + f(10100 \mid p, AAAAD) P(AAAAD \mid \theta) + f(10100 \mid p, AAAAA) P(AAAAA \mid \theta)$ Bu ifadeyi değişkenler cinsinden genişlettiğimizde karşımıza çıkan yapı, Markov zincirlerini anımsatan ancak onlardan çok daha zarif bir zaman serisi açılımıdır: $= p(1-p)p * [\theta] + p(1-p)p(1-p) * [(1-\theta)\theta] + p(1-p)p(1-p)(1-p) * [(1-\theta)^2 (1-\theta)^0]$ Bu denklemi dikkatle incelersek (μ) azzam bir bilgi sıkıştırma (data compression) gerçeği ile karşılaşırız: İşlemlerin tam sırasının (10100 mü, yoksa 01100 mü olduğu) hiçbir önemi yoktur! İhtiyacımız olan tek şey, sıfır-dereceli (zero-order) rastlantısallık özelliği sayesinde iki basit özet istatistiktir: Sıklık (Frequency, x - toplam satın alma sayısı) ve Yenilik (Recency, t_x - son satın almanın gerçekleştiği işlem fırsatının zaman indeksi). Bu, milyonlarca müşteriye sahip devasa bir veritabanını, sadece 22 satırlık bir tabloya indirgeyebileceğimiz anlamına gelir (Sparsity problemi burada zarifçe aşılar). Bu durumda rastgele bir x , t_x ve n (toplam işlem fırsatı) için p ve θ 'ya bağlı olabilirlik fonksiyonu $(\mu)_z$ (Denklem 4) şu şekilde genel forma kavuşur: $L(p, \theta \mid x, t_x, n) = p^x (1-p)^{n-x} (1-\theta)^n + \sum_{i=0}^{n-t_x-1} p^x (1-p)^{t_x-x+i} \theta (1-\theta)^{t_x+i}$ Ancak gerçek dünyada hiçbir müşterinin p ve θ değerini bilemeyiz; onlar gizli (latent) değişkenlerdir. Bu yüzden Bayesyen çerçevenin gereği olarak, bu fonksiyonun p ve θ 'nın popülasyon üzerindeki Beta dağılımlarına göre

beklenen değeri (expectation) almak için çift katlı integral (double integral) işlemi uyguluyoruz. $L(\alpha, \beta, \gamma, \delta | x, t_x, n) = \int_0^1 \int_0^1 L(p, \theta | x, t_x, n) f(p | \alpha, \beta) f(\theta | \gamma, \delta) dp d\theta$ İşte Beta dağılımının eşlenik (conjugate) yapısının sihir gibi çalıştığı an burasıdır. Karmaşık entegraller, Euler'in Beta fonksiyonu tanımları kullanılarak kapalı formulu, $\gamma(\gamma)$ fonksiyonlarına dönüştürülebilir, tamamen cebirsel terimler silsilesine (Denklem 5) dönüşür. Bu denklem, makalenin kalbidir ve Log-Olabilirlik (Log-Likelihood) maksimizasyonunda doğrudan hedef fonksiyonu (objective function) olarak optimize edilir.

4. Beklenen Değerler, Tahminsel Mantık ve CLV (Müşteri Yaşam Boyu Değeri)

Modelin parametreleri $(\alpha, \beta, \gamma, \delta)$ MLE (Maximum Likelihood Estimation) ile tüm popülasyon üzerinden hesaplandıktan sonra, makale en kritik iş dünyası sorularına yönelir: Gelecekte ne olacak? Bunu bulmak için olasılık kütle fonksiyonunu (PMF) ve beklenen değeri türetirler. Rastgele seçilmiş bir bireyin gelecekteki 'n' işlem fırsatında tam olarak 'x' işlem yapma olasılığı, makalede Denklem (7) olarak verilmiştir ve son derece karmaşık Beta fonksiyonu oranlarının bir kombinasyonudur. Ancak yöneticiler için çok daha önemli olan, bir kohortun (grubun) n dönem boyunca "beklenen" ortalama işlem sayısıdır (Denklem 8): $E(X(n) | \alpha, \beta, \gamma, \delta) = \frac{\alpha}{\alpha + \beta} * \frac{\delta}{(\gamma - 1) * [1 - \frac{\gamma}{\gamma + \delta}]^{\gamma + n} - \frac{\gamma}{\gamma + \delta} * \frac{\delta}{\gamma + \delta}^{\gamma + n}]$ Bu denklemde $\frac{\alpha}{\alpha + \beta}$, popülasyonun ortalama satın alma olasılığını $E(p)$ temsil ederken, yanındaki karmaşık çarpan hayatta kalma sürecinin beklenen etkisini, bir tür "zamanla aşınma" (decay) faktörü olarak formüle eder. Gelecekteki n dönem için (Denklem 10) yapılan kestirimlerde, bu yapı sadece başlangıç noktasını ileri kaydırmaktan ibarettir. Ancak en derin analitik güç, Koşullu Beklentilerde (Conditional Expectations) yatar. Elimizde t_x (son işlem zamanı) ve x (işlem sayısı) olan bir müşterinin, gelecekteki n dönemde kaç işlem yapması beklenmektedir? Bu, müşterinin halen "hayatta" (alive) olma olasılığının (Denklem 11) hesaplanmasıyla başlar. Bayes teoremi kullanılarak, elimizdeki (x, t_x) verisi ışığında, o müşterinin gizli θ 'sının güncellenmiş (posterior) dağılımını buluruz. Makale, bir müşterinin geçmişinde ne kadar boşluk (hiatus) varsa, ölüm olasılığının o kadar yüksek olduğunu ispatlar. İlginçtir ki, yüksek frekansla ($x=4$) satın alıp

son yıl satın almayan birinin "ölü" olma olasılığı, hayatında sadece bir kez ($x=1$) satın alıp son yıl satın almayan birine göre paradoksal olarak çok daha yüksektir! Çünkü $x=4$ olan kişi için "şansa satın almama" olasılığı teorik olarak çok düşüktür; eğer satın almadıysa büyük ihtimalle "ölmüştür" (kuru(\mu) terk etmiştir). İşte Bayesyen "Ortalamaya Dönüş" prensibi, verideki bu gizli gerçeği acımasızca yüzümüze çarpar. İndirgenmiş Beklenen Kalan İşlemler (DERT) ve **Gauss Hipergeometrik Fonksiyonu** Müşteri Yaşam Boyu Değeri (CLV) hesaplamalarında, gelecekteki işlemlerin bugünkü değeri (Present Value) hesaplanmalıdır. Gelecekteki bir işlemin değeri, sermayenin maliyeti (discount rate, d) oranında iskonto edilir. Pareto/NBD modelinde DERT'i hesaplamak için ikinci türden (confluent) hipergeometrik fonksiyonlara ihtiyaç duyulurken, BG/BB modelinde bu iş Gauss Hipergeometrik Fonksiyonu ${}_2F_1$ ile (Denklem 14) çözülür. Gauss hipergeometrik fonksiyonu ${}_2F_1(a,b;c;z)$, diferansiyel denklemler teorisinin en köklü çözümlerinden biridir ve Taylor serisi açılımları aracılığıyla yakınsayan bir sonsuz seri olarak tanımlanır. Bu fonksiyon, iskonto oranı ' d ' sistem içine dahil edildiğinde ortaya çıkan zaman serisi geometrik sonsuz toplamalarının integrali alındığında, analitik bir zorunluluk olarak ortaya çıkar. BG/BB modelinin zarafeti, bu karmaşık fonksiyonun bile, kohort seviyesinde yalnızca bir kez hesaplanmasının yeterli olması ve hantal integrasyonlardan bizi kurtarmasıdır.

5. Modelin Uzantıları: Gizli Değişkenler Arası Korelasyon, Sarmanov ve SBB Dağılımları

Makalenin son bölümü, entelektüel olarak en kışkırtıcı tartışmalardan birine, Varsayım 6'nın (p ve θ)'nın bağımsızlığı) esnetilmesine ayrılmıştır. İnsan doğası gereği, kuruma derinden bağlı, p (satın alma) olasılığı yüksek olan birinin, θ (terk etme) olasılığının da düşük olması beklenir. Yani aralarında negatif bir korelasyon olmalıdır. Ancak orijinal BG/BB, Beta önsel (prior) dağılımlarının birbirinden bağımsız olduğunu varsayar. Bu kısıtlamayı aşmak için literatürde sıklıkla Sarmanov dağılım ailesi kullanılır. Sarmanov dağılımları, belirlenmiş marjinal dağılımları koruyarak bivariat (iki değişkenli) ortak dağılımlar yaratmamıza olanak tanır. Ancak Sarmanov yaklaşımının sınırları vardır; oluşturabileceği korelasyon katsayılarının aralığı (range), marjinal dağılımların parametreleri tarafından dar bir tünele hapsedilir. Korelasyon -1 ile 1 arasında serbestçe dolaşamaz. Bu yetersizlik karşısında makale, istatistiksel literatürün derinliklerinden "SBB Dağılımını" (Logit-Normal distribution) çıkarır. SBB, p ve θ değerlerinin logit dönüşümlerinin ($\log(x/(1-x))$) bivariat Normal (Gaussian) dağılım izlediğini varsayar. Bu

dönüşüm $[0,1]$ aralığındaki değişkenleri $(-\infty, +\infty)$ aralığına genişletir ve iki değişken arasına dilediğimiz gibi bir kovaryans/korelasyon (sigma matrisi) yerleştirmemizi sağlar. Bunun bedeli nedir? SBB dağılımı kullanıldığında, Beta dağılımının (μ) azzam eşlenik (conjugate) özelliği kaybolur! Denklem 4'ün beklentisini almak için artık çift katlı integrallerin analitik kapalı formülü bir çözümü yoktur. Araştırmacılar bu durumda, Markov Chain Monte Carlo (MCMC) veya Maksimum Simüle Edilmiş Olabilirlik (Maximum Scaled Likelihood) yöntemleri kullanarak, algoritmik kaba kuvvetle integralleri sayısal olarak çözmek zorundadırlar. Sonuçlar büyüleyicidir. P ve θ arasında anlamlı bir önsel (prior) korelasyon bulunmasına rağmen ($r = 0.361$), orijinal BG/BB modeli ile SBB-G/B (Logit-Normal) modeli tahminleri arasında devasa farklar oluşmamıştır. Orijinal BG/BB modelinin marjinal posterior dağılımları incelendiğinde (Simpson's Paradox), modelin zaten kendi içinde, bağımsızlık varsayımına rağmen verideki gizli korelasyonu sezgisel bir Bayesyen düzeltme ile yakaladığı ortaya çıkmıştır. Bu durum, BG/BB'nin basitliğinin altında yatan (μ) azzam direnci ve analitik gücü kanıtlamakta, insan davranışını tahmin etmede veri biliminin ulaştığı zirve noktalardan biri olarak tarihe geçmektedir.

6. Sonuç ve Yönetmel Çıkarımlar

Makalenin derinlemesine analizi sonucunda, salt deterministik ve sürekli zamana dayalı modellerin (Pareto/NBD gibi) yöneticileri nasıl yanılttığı açıkça görülmüştür. Kurumsal kaynak planlaması, pazarlama bütçesi tahsisi ve müşteri sadakati programları tasarlanırken şu kritik yönetmel çıkarımlar göz önünde bulundurulmalıdır: Birincisi, Seyreklik (Sparsity) Tuzağından Kaçınma: Yıllık abonelikler, bağışlar veya dönemsel alımlar gibi işlemler doğası gereği ayrıktır. Müşterinin belirli bir zaman diliminde işlem yapmaması onun "öldüğü" ((μ) terk ettiği) anlamına gelmez. BG/BB modeli, yöneticilere sessiz kalan ama aslında hayatta olan (alive) müşterilerle, gerçekten sistemi terk etmiş (dead) müşterileri istatistiksel bir keskinlikle ayırma imkanı sunar. Bu sayede geri kazanım (win-back) kampanyaları sadece doğru kitleye yönlendirilir ve pazarlama bütçesi israfı önlenir. İkincisi, Ortalamaya Dönüş (Regression to the Mean) Prensibine Saygı: Bir müşterinin çok kısa sürede çok sık işlem yapması, onun gelecekte de aynı performansı sergileyeceğinin garantisi değildir. Bayesyen mantık çerçevesinde, ekstrem davranış sergileyen müşterilerin zamanla popülasyon ortalamasına döneceği unutulmamalıdır. Modelin sunduğu Koşullu Beklentiler (Conditional Expectations) ve DERT (İndirgenmiş Beklenen Kalan İşlemler) metrikleri, gelecekteki değerin gerçekçi ve

iskonto edilmiş net bir haritasını çizer. Bir müşterinin değeri, geçmişteki rekor işlemlerinden ziyade, yenilik (recency) ve sıklık (frequency) arasındaki karmaşık ilişkinin olasılıksal doğasında gizlidir. Üçüncüsü, Gizli Parametrelerin Stratejik Gücü: Satın alma olasılığı (p) ve kuru(μ) terk etme olasılığı (θ) arasındaki ilişki, tek boyutlu bir analizle anlaşılamaz. SBB (Logit-Normal) uzantılarıyla gösterildiği gibi, müşterilerin sadakatini modellemek için bu parametreler arasındaki gizli korelasyonu (Simpson Paradoksu) kavramak zorunludur. Stajyerden üst düzey yöneticiye kadar herkesin anlaması gereken temel felsefe şudur: Müşteri bir veri noktası değil, karar mekanizmaları olasılık dağılımlarına bağlı bir yapıdır. Sonuç olarak, BG/BB modeli ve ardındaki Bayesyen altyapı, kurumlara sözleşmesiz ve ayırık zamanlı işlemlerde müşterilerinin zihinlerine ve gelecek planlarına istatistiksel bir pencere açar. Bu kılavuzdaki matematiksel ve felsefi yoğunluk, yüzeyin altındaki gerçeği görmek ve rekabet avantajını şansa (salt ortalamalara) bırakmamak için inşa edilmesi gereken analitik kültürün yapıtaşdır. İş stratejilerini bu olasılıksal gerçekler üzerine kuran organizasyonlar, müşterilerini anlamada rakiplerinin fersah fersah önünde olacaktır.

4. MÜŞTERİ ELDE TUTMA PROJEKSİYONLARI VE SBG MODELİ

HOW TO PROJECT CUSTOMER RETENTION

1. Giriş: Müşteri Yaşam Boyu Değeri (CLV) Neden Hatalı Hesaplanır?

Müşteri ilişkileri yönetiminde (CRM) nihai amaç, bir müşterinin şirkette kaldığı süre boyunca getireceği toplam karı, yani Müşteri Yaşam Boyu Değerini (Customer Lifetime Value - CLV) hesaplamaktır. Fader ve Hardie, makalelerinin en başında standart ders kitaplarında yer alan CLV formülünü masaya yatırır: $E(CLV) = \text{Toplam} [m * S(t) / (1+d)^t]$ Burada 'm' müşterinin her dönem (örneğin her yıl) getirdiği net kar marjıdır. 'd' iskonto oranıdır (discount rate - paranın zaman değeri, yani bugünkü paranın yarınki paradan daha değerli olması). 'S(t)' ise en kritik bileşendir: Hayatta Kalma Fonksiyonu (Survivor Function), yani müşterinin 't' yılına kadar aktif kalma ihtimalidir. İşte Fader ve Hardie'nin isyan ettiği nokta tam olarak burasıdır: Şirketler 'm' (marj) ve 'd' (iskonto) değerlerini çok iyi hesaplar, ancak S(t) değerini geleceğe doğru yansıtırken (project ederken) akıl almaz hatalar yaparlar. Elimizde 5 yıllık bir müşteri verisi (S(1)'den S(5)'e kadar) varken, CLV'yi sadece bu 5 yıl üzerinden hesaplamak, 5. yıldan sonra sistemde kalacak (S(6), S(7)...) olan devasa sadık kitleyi tamamen yok saymak demektir. Bu da şirketin paha biçilemez bir değeri çöpe atmasına neden olur.

2. İstatistiksel Eğri Uydurmanın Çöküşü: Neden Matematiksel Fonksiyonlar Geleceği Göremez?

Şirketler S(5)'ten sonrasını tahmin etmek için en kolaya kaçarlar: 5 yıllık veriye bir regresyon eğrisi oturtmak. Fader ve Hardie, bu makalede 'High End' ve 'Regular' adını verdikleri iki gerçek veri setinde (7 yıllık veri) 3 farklı popüler regresyon modelini denerler: Doğrusal (Linear), İkinci Dereceden (Quadratic) ve Üstel (Exponential). Şekil 1: High End Segmentinde Eğri Uydurmanın Felaketle Sonuçlanması Şekil 1'de siyah kesintisiz çizgi gerçek veridir. 7. yıla kadar kesik çizgilerin hepsi mükemmel bir uyum

sergiler ($R^2 > 0.95$). Ancak 7. yıldan sonra (geleceği tahmin etme aşamasında) felaket yaşanır: - Doğrusal (Linear) Model: $S(t) = 0.925 - 0.071t$. Bu denkleme göre her yıl müşteri sayısı aynı oranda azalacaktır. Sonuç olarak doğrusal çizgi 14. yılda X eksenini delip geçer. Yani şirket 14. yılda eksi (-) sayıda müşteriye sahip olur. Bir müşteri havuzu negatif rakamlara düşemeyeceği için bu istatistiksel yaklaşım tamamen çöker. - İkinci Dereceden (Quadratic) Model: $S(t) = 0.997 - 0.142t + 0.010t^2$. Bu denklem U şeklindedir. 7. yıla kadar harika inerken, formüldeki pozitif $+t^2$ terimi devreye girer ve eğri havaya kalkar. Bu, iptal edip giden bir müşterinin 10. yılda (\mu)cizevi bir şekilde tekrar sisteme döndüğü anlamına gelir. Hayatta kalma fonksiyonu $[S(t)]$ asla ama asla ARTAMAZ (monotonik olarak azalmak zorundadır). Dolayısıyla Quadratic model de mantık dışıdır. Şekil 2: Regular Segmentinde Felaketin Büyümesi Şekil 2'deki Regular müşteri segmentinde bu mantıksız savrulmalar çok daha şiddetlidir. Fader ve Hardie'nin çıkardığı ders nettir: Geçmişe ne kadar iyi uyarsa uysun, içinde MÜŞTERİ DAVRANIŞINA DAİR İNSANİ BİR HİKAYE (STORY) barındırmayan hiçbir istatistiksel model (Parametric approaches) görünmeyen geleceği (out-of-sample forecasting) tahmin edemez.

3. sBG (Shifted-Beta-Geometric) Modelinin Devasa İspatı ve Olasılıksal Mimari

Yazarlar eğri uydurmayı çöpe atıp, iki temel davranışsal aksiyom üzerine kurulu sBG modelini inşa ederler. Aksiyom 1: Kaydırılmış Geometrik Dağılım (Shifted-Geometric Distribution) Müşteri her abonelik döneminin sonunda cebinden bir bozuk para çıkarır. Bu paranın tura (devam) gelme ihtimali $1-\theta$, yazı (iptal/churn) gelme ihtimali θ 'dır. Müşteri için bu θ değeri tüm ömrü boyunca SABİTTİR. Bir olayın (yazının) ilk defa gerçekleşmesine kadar geçen süre Geometrik Dağılımdır. Olasılık Kütle Fonksiyonu (PMF): $P(T = t | \theta) = \theta * (1 - \theta)^{(t-1)}$ Hayatta Kalma Fonksiyonu (Survivor): $S(t | \theta) = (1 - \theta)^t$ Yani müşteri, t yılına kadar hayatta kalmak istiyorsa peş peşe t defa tura $(1-\theta)$ atmak zorundadır. Aksiyom 2: Beta Dağılımı ve Evrensel Çeşitlilik (Heterogeneity) Her müşterinin cebindeki paranın hile oranı (θ) aynı değildir. Kimi aşırı sadık ($\theta=0.01$), kimi vefasızdır ($\theta=0.90$). Popülasyondaki bu milyonlarca farklı θ değerini 0 ile 1 aralığında modelleyebilen tek sürekli (continuous) dağılım Beta Dağılımıdır. Olasılık Yoğunluk Fonksiyonu (PDF): $f(\theta | \alpha, \beta) = \frac{\theta^{\alpha-1} * (1-\theta)^{\beta-1}}{B(\alpha, \beta)}$ Şekil 3: Beta Dağılımının Alfa ve Beta Parametrelerine Göre Çizdiği Karakter Şekilleri Şekil 3, müşteri kitlenizin ruhunun fotoğrafıdır. Sol üst köşe L şeklindedir (Müşterilerin ezici çoğunluğu $\theta=0$ 'a yakındır, çok sadıklardır). Sağ üst köşe Çan eğrisidir (Homojen bir şekilde herkes ortalama bir iptal riskine sahiptir). Sol alt köşe

U şeklindedir (Toplum ortadan ikiye yarılmıştır; ya aşırı sadıklar ya da hemen kaçacaklar vardır). Modelimizin tüm amacı, sadece iki sihirli parametreyi (Alfa ve Beta) bularak sizin şirketinizin hangi şekildeki müşteri kitlesine sahip olduğunu deşifre etmektir. Appendix A (Ek A): Modellerin Birleşimi ve İntegral İspatları Peki, müşterinin θ değerini dışarıdan göremiyorsak, geleceği nasıl tahmin edeceğiz? Makalenin Ek A kısmı (Appendix A) bu zorluğun üstesinden şöyle gelir: Beklenen Değer İntegrali: Rastgele bir bireyin t anında iptal etme ihtimali $P(T=t)$, Geometrik dağılımın Beta dağılımı üzerinden 0'dan 1'e kadar integrali alınarak (ağırlıklandırılarak) bulunur: $P(T=t) = \int_0^1 P(T=t|\theta) * f(\theta|\alpha, \beta) d\theta$ İntegralin Çözümü: Bu integral, Gamma Fonksiyonlarının $\Gamma(x+1) = x*\Gamma(x)$ şeklindeki özyineli (recursive) doğası sayesinde, korkunç karmaşıklıkta bir denklemden şu (μ) azzam derecede basit yapıya dönüşür: sBG $P(T=t | \alpha, \beta) = B(\alpha+1, \beta+t-1) / B(\alpha, \beta)$ İleri Yönlü Rekürsion (Forward Recursion): Bilgisayara integral hesaplatmak yerine yazarlar sistemi çok hafifletir. Bir sonraki yılın iptal ihtimali, bir önceki yıla bağlanır: $P(T=t) = P(T=t-1) * (\beta+t-2) / (\alpha+\beta+t-1)$ ($t=2,3... için$)

4. Bilimi Sarsan Gerçek: "Heterogeneity's Ruses" (Heterojenlik Yanılsaması)

Bir CRM (Müşteri İlişkileri) departmanına gidin. Zaman geçtikçe Retention Rate'in (Yenileme Oranı) yükseldiğini göreceksiniz. Yani sistemde 1. yılını dolduranların %60'ı yenilerken, sistemde 6. yılını dolduranların %90'ı yenileme yapacaktır. Yöneticiler bunu büyük bir zafer olarak sunar: 'Müşterilerimiz bizimle zaman geçirdikçe bize bağlanıyor, sadakatleri artıyor!' Fader ve Hardie bu noktada Vaupel ve Yashin'in (1985) ünlü kavramı 'Heterojenlik Hilesi / Yanılsaması (Heterogeneity's Ruses)' kavramını vurucu bir şekilde açıklar. GERÇEKTE HİÇ KİMSENİN SADAKATI ZAMANLA ARTMAZ. Modelin 1. Aksiyosunda belirttiğimiz gibi, bireyin iptal ihtimali (θ) ölene kadar sabittir. Peki ortalama neden artar? Sınıflandırma Etkisi (Sorting Effect) yüzünden! Yüksek θ değerine (kötü niyete / vefasızlığa) sahip müşteriler, ilk 2-3 yıl içinde havuzu zaten terk ederler. Geriye havuzun dibinde sarsılmaz derecede sadık, düşük θ 'ya sahip kitle kalır. Çürük elmalar ayıklandığı için matematiksel genel ortalama (aggregate retention) mecburen yukarı çıkar. Eğer siz bir bireyin sadakatinin zamanla arttığını varsayarsanız, CLV değerini inanılmaz derecede abartır ve şirketi batırırsınız. sBG modeli işte bu yanılsamayı denkleminde deşifre eder. Şekil 5: Retention Rate (Elde Tutma Oranı) Eğrisi ve Yanılsamanın Tahmini Şekil 5 bu yanılsamanın grafiğe dökülmüş halidir. Gerçek verideki tırmanan eğrileri sBG modeli (kesik çizgiler) kusursuzca takip etmektedir.

5. sBG Modelinin Görsel Zaferi ve Parametre Tomografisi

Şekil 4: sBG Modelinin Hayatta Kalma Tahminlerinde Şov Yapması Şekil 4'te sBG modelinin başarısı ortadadır. Eğri uydurma modellerinin havaya fırladığı veya eksiye düştüğü o korkunç 7. yıldan (dikey kesik çizgiden) sonra bile sBG modeli gerçeğe (Actual) tıpkı bir gölge gibi sadıktır. Çünkü sBG modelinin denklemi yukarı doğru dönemez veya eksiye düşemez. Doğası gereği 0 ile 1 arasına sınırlandırılmış bir olasılık kuramıdır. 12. yıldaki hata payı neredeyse yok denecek kadar azdır. Şekil 6: Alfa ve Beta Değerleriyle Çizilen Müşteri Tomografisi Şekil 6, Excel Solver ile bulunan Alfa ve Beta değerlerinin (High End için $\alpha=0.688$, $\beta=3.806$; Regular için $\alpha=0.704$, $\beta=1.182$) fonksiyona dökülmüş resmidir. İki eğri de Ters-J (veya L) şeklindedir. High-End grubu (düz çizgi) sola devasa bir yığılma yapmıştır; yani $\theta=0$ (iptal ihtimali sıfır) olanların yoğunluğu (\mu) azzamdır. Regular grup (kesik çizgi) ise sağa doğru kaymıştır, yani θ 'sı yüksek olan vefasızların oranı daha fazladır.

6. Sistemin Çılgınlığı: Tüm Matematik Sadece Excel'de Çözülüyor (Appendix B)

Yazarlar bu dahiyane olasılık kuramını çözmek için yapay zeka, Python veya derin öğrenmeye (\mu)htaç bırakmazlar. Her şey Excel'deki En Büyük Olabilirlik Kestirimi (Maxi(\mu)m Likelihood Estimation - MLE) ile çözülür. MLE şudur: 'Benim veritabanımda 1. yıl 131 kişi iptal etmiş, 2. yıl 126 kişi iptal etmiş... Bana öyle bir Alfa ve Beta değeri bul ki, bu Alfa ve Beta ile hesaplanan S(t) denklemi tamı tamına bu 131 ve 126 rakamlarını üretecek ihtimali en zirveye (maks(\mu)ma) taşınsın.' Şekil B1: sBG Modelinin Excel MLE Mimarisi Şekil B1'de sistem kurul(\mu)ştur. B sütununda anlattığımız Rekürsif (Özyineli) sBG formülü çalışır. E sütununda kaybedilen gerçek müşteri sayıları vardır. F sütunu (Log-Likelihood), B sütunu ile E sütununun logaritmik çarpımından doğan matematiksel olasılıktır. Bu değerlerin toplamı B3 hücresinde toplanır (LL değeri: -2115.5). Eksi sonsuza inen bu rakamı, eksi sayılarda sıfıra en yakın yere (maks(\mu)m tepeye) çekmemiz gerekir. Şekil B2: Excel Çözücü (Solver) Ayarları Şekil B2 Excel'in Solver (Çözücü) ekranıdır. Hedef Hücre B3 seçilir. Equal To: MAX (Maks(\mu)m yap) seçilir. By Changing Cells (B1:B2) yani Alfa ve Beta hücreleriyle oyna denir. Bilgisayar saniyeler içinde binlerce deneme yapar ve B3'ü zirveye çıkaran nihai Alfa=0.668 ve Beta=3.806 değerini bulur. Şekil 4'teki (\mu)azzam gelecek tahminlerini çizen şey işte bu ufacık Excel algoritmasıdır.

7. Literatür Sınıflandırması: Fader ve Hardie'nin 2x2 Matrisi

Makalenin son bölümü ('Limits to Application') bu sBG modelinin nerelerde KULLANILMAMASI gerektiğini (\mu)azzam bir 2x2 matrisle açıklar:

1. İşlem Fırsatları (Frekans): Ayırık Zamanlı (Discrete) vs Sürekli Zamanlı (Continuous). Eğer işlemler her ay sonu fatura kesimi gibi belli periyotlardaysa Discrete'dir. Amazon'da anlık alışveriş yapmak gibi istenilen saniye olabiliyorsa Continuous'tur.

2. İlişki Türü: Sözleşmeli (Contractual) vs Sözleşmesiz (Noncontractual).

Bizim bu makalede anlattığımız sBG modeli, AYRIK ZAMANLI SÖZLEŞMELİ (Discrete Contractual) sistemler içindir. Diğer kutularda Fader ve Hardie'nin diğer ünlü modelleri yatar: - Sürekli Zamanlı Sözleşmesiz (Continuous Noncontractual): Pareto/NBD ve BG/NBD modelleri. - Ayırık Zamanlı Sözleşmesiz (Discrete Noncontractual): BG/BB modeli. - Sürekli Zamanlı Sözleşmeli (Continuous Contractual): sBG'nin sürekli zamanlı versiyonu olan Exponential-Gamma (EG) modeli ve Weibull-Gamma (WG) modelleri.

8. Nihai Sonuç ve Şirketler İçin Vizyon

Bu makale, müşteri ilişkileri yönetimini (CRM) regresyonların karanlık kuyusundan kurtarıp olasılık teorisinin güvenli sularına taşır. Bir yöneticinin önüne gidip 'Müşterilerimiz 12. yılda eksi 20 kişiye düşecek' demek yerine, 'Müşterilerimizin her biri farklı ayrılma olasılıklarına (Beta Dağılımı) sahiptir ve geriye sadece sadıklar kalacağı için iptal oranımız %4 civarında yataya bağlayacaktır (sBG Modeli)' diyebilmek, CLV hesaplamalarında şirketin borsadaki değerlemesini bile doğrudan etkileyecek matematiksel bir devrimdir.

5. DERİN ÖĞRENME İLE SIRALI (SEQUENTIAL) CHURN TAHMİNİ

Modelling customer churn for the retail industry in a deep learning based sequential framework

1. Giriş: Sözleşmesiz Perakende Sektöründe Müşteri Kaybının Doğası

Veri bilimi dünyasında Müşteri Kaybı (Churn) Tahmini, endüstrinin doğasına göre iki ana kategoriye ayrılır: Sözleşmeli (Contractual) ve Sözleşmesiz (Non-Contractual) sistemler. Netflix, Spotify veya Telekom operatörleri gibi sözleşmeli sistemlerde bir müşterinin churn olup olmadığını anlamak son derece basittir; müşteri üyeliğini iptal eder ve veritabanına doğrudan bir 'Churn=1' etiketi düşer. Ancak süpermarketler, giyim mağazaları, e-ticaret siteleri (Amazon, Trendyol vb.) gibi sözleşmesiz perakende ortamlarında müşteriler markayı terk ettiklerini asla beyan etmezler. Sadece sessizce alışveriş yapmayı bırakırlar. İşte bu makalenin çözmeye çalıştığı en temel ve en zorlu problem budur: 'Bir müşterinin son alışverişinden bu yana geçen sessiz sürenin (örneğin 3 ay), o müşterinin kalıcı olarak kaybedildiğini (churn) mi gösterdiğini, yoksa o müşterinin zaten alışkanlık gereği 4 ayda bir mi alışveriş yaptığını nasıl ayırt edeceğiz?' Geleneksel yaklaşımlar (örneğin Pareto/NBD - Negative Binomial Distribution modelleri veya RFM - Recency, Frequency, Monetary matrisleri) bu ayrımı yapmakta yetersiz kalmaktadır. Aynı şekilde Lojistik Regresyon ve Rastgele Orman (Random Forest) gibi klasik ikili sınıflandırma (binary classification) modelleri, bu 'belirsizlik' durumu(\mu)nu kavrayamaz. Çünkü onlar her müşterinin o an için kesinlikle 0 (aktif) veya 1 (churn) olmasını beklerler. Bu katı yapı, veri bilimcileri aylar süren ve çoğu zaman hatalı varsayımlara dayanan manuel 'Özellik Mühendisliği (Feature Engineering)' yapmaya zorlar.

2. Matematiksel Çerçeve: Hayatta Kalma Analizi (Survival Analysis) ve Sansürleme (Censoring)

Makale, makine öğrenmesinin bu yetersizliğini aşmak için tıp dünyasından ödünç alınan Hayatta Kalma Analizi (Survival Analysis) teorisini kullanır. Tıpta bir hastanın kanser teşhisinden sonra ne kadar süre hayatta kalacağı modellenirken, perakendede bir müşterinin 'bir sonraki alışverişine kadar ne kadar süre hayatta kalacağı (bekleyeceği)' modellenir. Hayatta Kalma Fonksiyonu $S(t)$: Hayatta kalma analizi, olasılık teorisine dayanır. Temel formülü $S(t) = P(T > t) = 1 - F(t)$ şeklindedir. Burada T , bir sonraki işlemin gerçekleşeceği rastgele (stokastik) zamanı temsil eder. $S(t)$ ise bu T zamanının, bizim belirlediğimiz bir ' t ' süresinden daha büyük olma olasılığıdır. Başka bir deyişle $S(t)$, müşterinin ' t ' anına kadar işlem yapmama (hayatta kalma) ihtimalidir. Zaman (t) ilerledikçe bu ihtimal doğal olarak 1.0'dan (yüzde 100) 0.0'a doğru azalır. Tehlike Oranı (Hazard Function) $\gamma(t)$: Tehlike oranı, t anına kadar hayatta kalmış bir müşterinin tam o an (sonsuz küçüklükte bir zaman diliminde) alışveriş yapma (veya sistemi terk etme) riskidir. Matematiksel olarak $\gamma(t) = S'(t) / S(t)$ formülüyle ifade edilir (S' fonksiyonun türevidir). 2.1. Veri Madenciliğinin En Büyük Engeli: Sağdan Sansürleme (Right Censoring) Elinizdeki veritabanını dondurup 1 Ocak tarihinde bir rapor çıktığınızı düşünün. Müşterilerden biri son alışverişini 15 Aralık'ta yapmış olsun. 15 Aralık ile 1 Ocak arasındaki 16 günlük sürede bu müşteri yeni bir eylemde bulunmamıştır. Makine öğrenmesi algoritmaları bu müşterinin satırına bakıp '16 gündür hareket yok, o halde Churn = 1' demek ister. Ancak biz 1 Ocak'tayız, belki de bu müşteri 5 Ocak'ta gelip alışveriş yapacaktır. Yani olay (yeni alışveriş) bizim gözlem ufku(\mu)zun dışında, gelecekte bir yerde gerçekleşecektir. İşte bu duruma İstatistik biliminde Sağdan Sansürleme (Right Censoring) denir. Makalenin önerdiği model, bu 16 günlük sessizliği bir kayıp olarak etiketlemek yerine, modelin içine 'bu müşterinin dönüş süresi $T > 16$ gündür' bilgisini besler. Model belirsizliği reddetmez, aksine matematiksel bir değer olarak kucaklar. 2.2. Sıralı İşlem (Sequence Transaction) Verisinin Sisteme Tanıtılması (Şekil 3 Serisi) Şekil 3(A): İşlemsel (Transactional) Ham Verinin Görünümü ve Sansür Şekil 3(A) verinin zaman çizelgesini gösterir. Bir Customer k için geçmişteki işlemler ($d_{k,i}$) siyah noktalarla temsil edilir. Model, alışveriş günlerini değil, alışverişler arasında geçen SÜRELERİ girdi olarak kabul eder. Yani girdi vektörümüz $t_{k,i} = d_{k,i} - d_{k,i-1}$ şeklinde hesaplanan farklardan oluşur. Gri noktalar bizim henüz bilmediğimiz gelecekteki olaylardır. Kesik dikey çizgi ise analiz anımızdır. Şekil 3(B): Eğitim (Training) Fazı ve Üstel Dağılım Dalgaları Şekil 3(B) modelin nasıl eğitildiğini gösterir. Veri, analiz tarihinden bir miktar geriye sarılır (Observation period). Model geçmişteki siyah noktalara bakarak geleceği tahmin etmeye çalışır. Dikkat ederseniz her müşterinin kesik çizgisinin sağında gri, azalan bir dalga (eğri) bulunmaktadır. Bu dalga $\text{Exp}(\lambda_k)$ yani Üstel Dağılımdır (Exponential Distribution). Model her bir müşteri için 'bir

sonraki işlem şu olasılıkla şu zamanda gerçekleşecek' diyen kişiselleştirilmiş bir olasılık yoğunluk fonksiyonu üretir. Şekil 3(C): Doğrulama (Validation) Fazı Şekil 3(C)'de modelin ürettiği bu gri dalga (tahmin), gerçekte sonradan gerçekleşen yeni siyah noktalarla (gerçekleşen işlemlerle) kıyaslanır ve aradaki hata payı hesaplanarak modelin ağırlıkları güncellenir. 2.3. Verinin Doğası: Neden Üstel Dağılım (Exponential Distribution)? Şekil 2: Peş Peşe Gelen Alışverişler Arasındaki Sürenin Kümülatif Dağılımı (Logaritmik) Modelin müşteriler için $\text{Exp}(\lambda)$ dalgaları ürettiğini söyledik. Peki gerçek hayattaki müşteri verisi bu dağılıma uyuyor (μ)? Şekil 2 bu sorunun kesin kanıtıdır. Milyonlarca müşterinin iki alışverişi arasındaki sürelerin (gün bazında) kümülatif yığılması logaritmik bir eksene oturtulduğunda, ortaya kusursuz bir S-eğrisi (Sigmoid benzeri bir büyüme) çıkmaktadır. İstatistik biliminde bu form, bekleme sürelerinin ve rastgele gelişlerin Poisson veya Üstel Dağılım karakteristiğine sahip olduğunun matematiksel ispatıdır. Makale, varsayımlarını bu gerçek veri analizi üzerine inşa etmiştir.

3. Derin Öğrenme Mimarisi: RNN, LSTM ve Bayesyen Entegrasyon

Geleneksel hayatta kalma algoritmalarından Cox Proportional Hazard (CPH), tehlike oranının zamanla sabit kaldığını varsayar. Oysa bir müşteri evlendiğinde, taşındığında veya maaşı arttığında alışveriş frekansı (ritmi) değişir. Bu ardışık (sequential) ritim değişimini algılayabilmek için hafızaya sahip bir yapı gereklidir. İşte bu noktada Tekrarlayan Sinir Ağları (Recurrent Neural Networks - RNN) devreye girer. Şekil 1: Standart RNN Gizli Durum (Hidden State) Yapısı Şekil 1, RNN'nin kalbini gösterir. Klasik Yapay Sinir Ağları (YSA) birbirini takip eden olaylar arasında bağ kuramaz. Ancak RNN'de, t anındaki bir işlem (X_t - örneğin müşterinin 3. alışverişindeki gecikme süresi) ağa girdiğinde, ağ sadece o veriye bakmaz. Altındaki baklava dilimi olan h_t (Hidden State - Gizli Durum) vektörünü hesaplamak için, bir önceki adımdan gelen h_{t-1} vektörünü de işleme katar. Yani müşteri 10. alışverişini yaparken, model o müşterinin 1. alışverişindeki ritmini bile h_t vektörünün içinde şifrelenmiş olarak hatırlar. Şekil 4: Prosedürel Sinir Ağı Mimarisi ve Bayesyen (MCMC) Katmanları 3.1. Şekil 4: Modelin Uçtan Uca Detaylı Anatomisi Bu görsel, kodlamanın yapılacağı ana $o(\mu)$ rgadır. Katman katman işleyişi son derece detaylı bir şekilde inceleyelim: A) Girdi Dizileri (Input Sequences - TX): Model demografik veri almaz. Yalnızca müşterinin geçmiş alışverişleri arasındaki sürelerin vektörünü alır (Örn: [12 gün, 5 gün, 30 gün, 14 gün]). B) Uzun-Kısa Süreli Bellek (LSTM Layer): Klasik RNN'ler çok eski verileri hatırlamakta 'gradyan kaybolması' (vanishing

gradient)' sorunu yaşarlar. Makale, bu sorunu çözmek için LSTM hücrelerini kullanır. LSTM, 'Unutma Kapısı (Forget Gate)', 'Girdi Kapısı' ve 'Çıktı Kapısı' sayesinde müşterinin yıllar önceki çok önemli bir alışveriş davranışını saklarken, önemsiz sapmaları silme yeteneğine sahiptir. C) İleri Beslemeli Katmanlar (Feed-forward Layers): LSTM'den çıkan yüksek boyutlu ardışık hafıza vektörleri, klasik Çok Katmanlı Algılayıcı (Multilayer Perceptron - MLP) katmanlarından geçirilerek non-lineer (doğrusal olmayan) ilişkiler çözümlenir. D) Lambda Üretimi (λ_k): Son katman, 1 boyutlu bir Çıktı Düğümüdür ve Exponential (Üstel) aktivasyon fonksiyonu kullanılarak her müşteri için o müşterinin hızını belirten tek bir 'Lambda' oranı üretilir. (Output = $\text{Exp}(\lambda_k)$)

3.2. Yüzeysel Geçilen Kritik Konu: MCMC (Markov Chain Monte Carlo) ve Hamiltonian Sampling Makalede ve Şekil 4'ün sağ tarafında 'MCMC' ve 'Hamiltonian sampling' ifadeleri bulunur, ancak matematiksel derinliği metinde yüzeysel geçilmiştir. Bu konu sistemin belirsizliği nasıl yönettiğinin anahtarıdır. Geleneksel deterministik sinir ağları tek bir (μ)tlak değer üretir (Örn: 'Bu müşteri 10 gün sonra gelecek'). Ancak bu tür (μ)tlak tahminler risk yönetiminde kör noktalara sebep olur. Bayesyen Sinir Ağları (BNN), (μ)tlak bir sayı yerine bir 'Olasılık Dağılımı (Posterior Distribution)' üretir. Yani model, 'Müşteri 10 gün sonra gelebilir, ancak bu tahmine güvenim (varyansım) şu kadar' bilgisini de sunar. Ancak bu devasa karmaşık çok boyutlu sinir ağı uzayında (milyonlarca parametre varken) doğru olasılık dağılımını hesaplamak imkansızdır. Bu yüzden istatistikçiler 'Örnekleme (Sampling)' yaparlar. Klasik Markov Zinciri Monte Carlo (MCMC) rastgele yürüyüş (random walk) yapar ve çok yavaştır. Makalenin kullandığı Hamiltonian Monte Carlo (HMC) ise fiziksel kinetik ve potansiyel enerji yasalarından esinlenir. Algoritma, parametre uzayını bir yokuş gibi düşünür ve parametrelere bir 'momentum' (hız) vererek yokuşta kaydırır. Gradyanları (eğimleri) kullanarak bir sonraki örneklemin nerede olacağını rastgele değil, fizik kanunlarıyla hesaplar. Bu sayede Şekil 4'teki gri MCMC bloğu, son derece karmaşık dağılımlardan ışık hızında örneklemler ($t_{k,j+1}$) çekerek en sağdaki o pürüzsüz 'Hayatta Kalma Fonksiyonu (Survival function estimation)' eğrisini çizer.

3.3. Yüzeysel Geçilen Diğer Konu: Asimetrik Kayıp Fonksiyonları (LINEX / Balanced Loss) Yapay zeka modelleri Hata (Loss) fonksiyonlarını minimize ederek öğrenirler. Dünyadaki modellerin %90'ı Ortalama Karesel Hata (Mean Squared Error - MSE) kullanır. MSE simetriktir; eğer gerçek cevap 20 ise, modelin 10 demesi (10 birim eksik) ile 30 demesi (10 birim fazla) aynı cezayı ($10^2 = 100$) alır. Ancak Churn (Müşteri Kaybı) dünyasında ve sansürlü verilerde durum asimetriktir! Eğer bir müşterinin dönüş süresini 'çok kısa' tahmin ederseniz en fazla gereksiz bir promosyon SMS'i atarsınız (küçük zarar). Ancak dönüş süresini 'çok uzun' tahmin ederseniz müşteri soğur, rakiplere gider ve sonsuza dek

kaybedersiniz (büyük zarar). Bu yüzden makalede LINEX (Linear Exponential) Loss veya Balanced (Dengeli) Kayıp Fonksiyonları referans gösterilir. LINEX fonksiyonu ($L(u) = \exp(\alpha u) - \alpha u - 1$), hatanın bir yönünü üstel (exponential) olarak çok devasa sayılarla cezalandırırken, diğer yönünü doğrusal (linear) ve daha insaflı cezalandırır. Makaledeki modelin kendi eğitimi için seçtiği Negatif Log-Olabilirlik (Negative Log-Likelihood) fonksiyonu da sansürlü ve sansürsüz veriler ($\delta=1$ ve $\delta=0$ durumları) için iki ayrı toplam formülü kullanarak bu dengesizliği harika bir şekilde yönetir.

4. Modelin Performansı: Deneyler ve Ölçüm Metrikleri

Sistem hem 2.8 Milyon müşterilik gerçek devasa bir veri setinde (Retail Data) hem de kontrollü olarak üretilmiş 100.000 kişilik Gaussian Dağılımlı Sentetik veride (Synthetic Data) test edilmiştir. 4.1. Kullanılan Bilimsel Metrikler Nelerdir?

1. Brier Score: Hayatta kalma analizinde olasılık kalibrasyonunu ölçen en keskin metriklerden biridir. Sansürlemeyi hesaba katarak (Inverse Probability of Censoring Weights ile), gerçek durum ile tahmin edilen olasılık arasındaki karesel mesafeyi ölçer. Hata bazlı olduğu için değerin küçük olması (0'a yakın olması) modelin çok iyi olduğunu gösterir.

2. Concordance Index (Harrell's C-Index): İki rastgele müşteri seçildiğinde, olayı (örneğin churn) daha erken yaşayan müşteriye modelin de daha yüksek bir tehlike skoru verip vermediğini (doğru sıralama yapıp yapmadığını) ölçer. 0.5 tamamen şans eseri tahminken, 1.0 kusursuz bir sıralama yeteneğidir.

Şekil 6: Sentetik Verinin 12 Aylık Kaplan-Meier Yaşam Eğrileri Şekil 6, bilgisayar ortamında üretilen 100 bin kişilik sentetik verinin zaman içindeki davranış kümelerini (cohorts) Kaplan-Meier eğrisi ile gösterir. 12 farklı ay için oluşturulan eğrilerin birbirine tutarlı ve stabil şekilde sarılmış olması, deney ortamının ve simülasyonun (Gaussian (μ)=0.08, σ =0.02) doğru kurgulandığının kanıtıdır. 4.2. Müşteri Frekanslarına (Alışkanlıklarına) Göre Modelin Akıllı Adaptasyonu Şekil 7: Yüksek ve Düşük Frekans Gruplarında

Modellerin Tahmin Eğrileri (Gerçek ve Sentetik Veri) Şekil 9: Tüm Frekans Tahminlerinin Tek Bir Grafikte Toplu Analizi Şekil 7 ve Şekil 9, makalenin temel iddiasını ispatlayan devasa görsellerdir. Geleneksel Cox Modeli (CPH - mavi çizgi) ve temel Kaplan-Meier (KM - yeşil kesik çizgiler) ile Derin Öğrenme Ağımız (NN - siyah ve düz renkli çizgiler) kıyaslanmaktadır. Şekil 9 üzerinden detaylı yorumlama: Kırmızı düz çizgi ağımızın (NN) 'Az Alışveriş Yapan (Low-frequency)' müşteriler için çizdiği hayatta kalma $S(t)$ olasılığıdır. Az alışveriş yapan bir müşterinin 50 gün boyunca gelmemesi normaldir, dolayısıyla sistem bunu hemen 'churn' saymaz ve eğri yüksekte (güvenli bölgede) kalır. Yeşil düz çizgi ise ağımızın 'Sık Alışveriş Yapan (High-frequency)' müşteriler için çizdiği eğridir. Sık gelen biri 20 gün gelmediyse anormallik vardır, bu yüzden yeşil eğri hızla aşağıya çakılır. En kritik başarı: Siyah/Renkli düz çizgilerimiz (NN), her iki grupta da o grupların orijinal doğasına (kesik çizgili KM'lere) inanılmaz bir milimetrik uyumla yapışmaktadır. Geleneksel modeller (Örn Şekil 7'deki mavi CPH çizgileri) bu kadar esnemez, çoğu zaman yanılır ve genel ortalamaya doğru hata yaparlar. Derin Öğrenme, müşteri grubunun ruhunu ezberlemiştir. Şekil 8: Toplam Popülasyonda Derin Öğrenme ve KM Ortalama Kıyaslaması Şekil 8, modelin makro (genel) zekasını test eder. Ağın ürettiği milyonlarca kişisel tahminin ortalaması alınıp siyah çizgi oluşturulmuş, gerçek verinin toplam ortalaması da gri çizgi (KM-baseline) olarak çizilmiştir. Çizgiler birbirine sarılmıştır. Bu durum, modelimizin mikro düzeyde harika kişiselleştirme yaparken, makro popülasyon istatistiğinden kopmadığını, yani modelin gerçeklik algısını yitirmediğini (overfitting olmadığını) matematiksel olarak kanıtlar.

4.3. İvme ve Trend Yakalama: Soğuyan Müşterinin Tespiti

Şekil 10: Davranış Trendlerine Göre Lambda (λ) Dağılımları Şekil 11: Trend Değişimlerinin $S(t)$ Hayatta Kalma Eğrisine Etkisi Şekil 10 ve 11, sistemin davranış trendlerini okuyabildiğini gösterir. LSTM hafızası sayesinde ağ, sadece müşterinin frekansını değil, o frekansın ivmesini (artıyor (μ) azalıyor (μ)) de anlar. Şekil 10'da mavi sütunlar alışverişi giderek sıklaşan müşterilere ait hesaplanan ' λ ' oranları, turuncu sütunlar ise alışverişi giderek seyrekleşen (soğuyan) müşterilere ait ' λ 'lardır. Dağılımların tamamen farklı noktalarda kümelenmesi, ağın bu iki grubu farklı beyin loblarında değerlendirdiğini gösterir. Şekil 11'de bu ' λ 'ların eğriye yansması mevcuttur. Mavi çizgi (alışverişi sıklaşanlar) hızla aşağıya (sıfır risk bekleme süresine) inerken, turuncu çizgi (soğuyan ve artık daha geç gelen müşteriler) yukarıda kalır. Model, bir müşterinin firmadan yavaş yavaş koptuğunu (soğuduğunu) manuel hiçbir müdahale olmadan sadece fiş tarihlerine bakarak tespit edebilmektedir.

4.4. Bireysel Ekstrem Senaryolarda Nokta Atışı Tahmin Gücü

Şekil 12: Alt Segmentlerde Bireysel $S(t)$ Kıyaslamaları (Zorlu Durum Testi) Şekil 12, algoritmanın sınındığı son ve en zorlu testtir.

Müşteriler çok ekstrem davranış kombinasyonlarına göre 4'e bölünmüştür. Özellikle en tehlikeli grup olan 'High Frequency & High Recency' (Eskiden çok sık alışveriş yapardı ama son zamanlarda aniden ortadan kayboldu) tablosuna dikkatli bakın. Bu tabloda Kırmızı çizgiler (klasik KM) müşterinin aniden kaybolmasına mantıklı bir cevap üretmez ve kaba, köşeli, hatalı, zikzaklı basamaklar çizer. Oysa Siyah çizgi (Derin Öğrenme Ağımız - NN), müşterinin kendi kişisel rutini içinde büyük bir anormallik yaptığını anında hafızasından karşılaştırarak bulur ve risk eğrisini hızla aşağı çeker. Bu eğrinin anlamı şudur: 'Uyarı! Bu müşteri kendi standardının dışına çıktı, bu sessizlik normal değil, büyük ihtimalle rakip firmaya gitti (Churn oldu)'. Algoritmanın tek bir birey bazında böylesine kusursuz bir risk analizi yapması, bu mimarinin devrimsel yanıdır.

5. Sonuç: Model Kıyaslamasında Dürüstlük ve Çıkarım

Tüm bu kapsamlı inceleme sonucunda, RNN tabanlı Derin Öğrenme Mimarisinin sözleşmesiz perakende sektöründe çığır açtığı kanıtlanmıştır. Ancak makale bilimsel olarak son derece dürüst bir tablo ortaya koyar: Brier Score (Olasılık Kalibrasyonu) açısından RNN modeli geleneksel CPH (Cox) modelini ezip geçmiştir (0.303 gibi skorlarla RNN çok daha üstün bir hata minimizasyonu sağlamıştır). Ancak Concordance Index (C-Index - Sıralama yeteneği) metriklerinde geleneksel CPH modelinin (özellikle gerçek perakende verisinde) hala çok başarılı olduğu görülmüştür. Bunun nedeni, CPH modellerinin müşterinin demografik (yaş, maaş, cinsiyet) gibi verilerini denkleme kolayca katabilmesidir. Buna rağmen Derin Öğrenme Modeli, müşterinin YAŞI, MAAŞI veya CİNSİYETİ hakkında HİÇBİR ŞEY BİLMEYEN, sadece müşterinin fiş kesim tarihleri (zaman sekansları) üzerinden LSTM kullanarak CPH kadar, hatta olasılık isabetinde CPH'den çok daha üstün bir zeka sergilemiştir. Sektörel Sonuç: Şirketler, aylar süren maliyetli veri temizleme, özellik mühendisliği (feature engineering) ve manuel kural yazma eziyetlerinden kurtularak; sadece alışveriş zaman damgalarını (timestamps) alıp, müşterinin davranışsal trendini, soğumasını ve churn riskini tamamen otonom bir şekilde, üstel ve asimetrik matematiksel fonksiyonlarla optimize eden bu Derin Öğrenme sistemine geçiş yapabilirler.

6. MÜŞTERİ TABANI ANALİZİNDE TEMEL OLASILIK MODELLERİ ÖZETİ

Probability Models for Customer-Base Analysis

1. Giriş: İşlem Odaklılıktan Müşteri Odaklılığa (Customer-Centricity) Geçiş

Fader ve Hardie'nin (2009) bu makalesi, modern Veri Bilimi ve Pazarlama Matematiği literatürünün en önemli derlemelerinden biridir. Geleneksel şirketler ellerindeki devasa işlem (transaction) veritabanlarını sadece geçmiş raporlamak (Örn: Bu ay ne kadar sattık? Ortalama sepet tutarı ne?) için kullanırlar. Ancak makale, bu 'betimleyici (descriptive)' analizlerin ötesine geçip, doğrudan geleceği tahmin eden 'Müşteri Tabanı Analizine (Customer-Base Analysis)' geçişi savunur. Geleceği tahmin etmenin en bilimsel yolu 'Olasılık Modelleri (Probability Models)' kullanmaktır. Klasik veri madenciliği (Data Mining) veya Regresyon modelleri (Örn: Lojistik Regresyon) geçmiş ezberler. Ancak olasılık modelleyicileri, gözlemlenen davranışın aslında stokastik (rastlantısal) bir sürecin sonucu olduğuna inanırlar. Şekil 1: Olasılık Modelleyicisinin İşlem Sürecine Bakış Açısı

Şekil 1 bize bu 'Puslu Pencere (Foggy Window)' mantığını anlatır: Müşterinin geçmişteki satın almaları (Past kısmındaki çarpı işaretleri) onun gerçek doğasını tam olarak yansıtmaz. Belki müşteri normalde ayda 4 kez alışveriş yapan biridir ama o ay hastalandığı için 2 kez yapmıştır. Dolayısıyla bizim görevimiz geçmiş işlemlere (Past) bakarak, müşterinin beyninin içindeki o gizli karakteristiği, yani 'Latent Characteristics (θ)' değerini tahmin etmektir. Bu θ bulunduktan sonra, müşterinin gelecekteki (Future) satın almaları Bayes Teoremi kullanılarak matematiksel olarak hesaplanır.

2. Şirketlerin Anatomisi: Müşteri Matrisi ve Taksonomi (Sınıflandırma)

Tüm olasılık modelleri aynı değildir. Bir süpermarket ile bir cep telefonu operatörünün müşteri doğası tamamen farklıdır. Fader ve Hardie, dünyadaki tüm ticari ilişkileri 2 ana

eksende 4 çeyreğe (quadrant) bölen ünlü taksonomisini sunar: Şekil 2: Müşteri Tabanlarının 2x2 Matris ile Sınıflandırılması Şekil 2'deki matrisin eksenleri şöyledir:

1. Yatay Eksen (İlişki Türü): Contractual (Sözleşmeli) vs Noncontractual (Sözleşmesiz). Abonelik gerektiren (ölümün/churn'ün net olarak bilindiği) sistemler Sözleşmeli; Müşterinin ne zaman firmayı terk ettiğinin (ölümün) BİLİNMEDİĞİ, müşterinin sessizce kaybolduğu sistemler Sözleşmesizdir.

2. Dikey Eksen (İşlem Fırsatı): Continuous (Sürekli) vs Discrete (Ayrık). Müşterinin istediği an (örneğin Amazon'dan gece 03:00'da) işlem yapabildiği sistemler Sürekli; Sadece belirli bir zaman diliminde (Örn: her ayın 15'i fatura kesimi, yılda bir konferans) işlem yapılan sistemler Ayrık'tır.

3. En Zorlu Problem: Sözleşmesiz Sürekli (Continuous-Noncontractual) Ortamlar

Matrisin sol üst köşesi (Örn: Süpermarketler, E-ticaret siteleri, Doktor ziyaretleri), veri bilimciler için dünyadaki en zorlu problemdir. Çünkü müşteri üyeliğini iptal etmez, 'Sadece sessizce aşınır (silently attrite)'. Firmalar müşterinin ne zaman kalıcı olarak gittiğini asla bilemez. Şekil 3: Müşterilerin Geçmiş İşlem Geçmişleri (Kimin Churn Olduğunun Belirsizliği) Şekil 3 bu belirsizliğin kanıtıdır: 4 farklı müşterinin (A, B, C, D) 0 ile T zamanı arasındaki alışverişleri çarpı (x) ile gösterilmiştir: - Müşteri B ve C aynı sayıda (4 kez) alışveriş yapmıştır. Ancak C'nin son alışverişi aylar önce olmuştur. Bu yüzden C htemelen 'Ölmüş (Churn olmuş)' kabul edilirken, B hala hayattadır. - Müşteri A'nın da son alışverişi C ile aynı tarihtedir. Ancak A doğası gereği 'çok seyrek' alışveriş yapan biridir. Dolayısıyla A için bu uzun sessizlik normaldir, A hala 'Hayattadır (Alive)'. Ancak C doğası gereği sık alışveriş yapan biri olduğu için bu sessizlik onun 'Öldüğüne' işaretidir. 3.1. Çözüm: "Ölene Kadar Satın Al (Buy Till You Die - BTYD)" Modeli Müşteri ne zaman öldü belirsizliğini çözmek için literatürdeki en büyük buluş olan BTYD modelleri geliştirilmiştir. Bu modeller, müşterinin firmadaki yaşamını iki faza ayırır:

1. Hayatta Olma Fazı (Alive): Müşteri hayattayken belirli bir frekansla (Poisson dağılımı) rastgele satın almalar yapar.

2. Ölüm Fazı (Death): Müşteri belli bir an geldikten sonra (Exponential dağılım), aniden ve tamamen sistemi terk eder. Ancak bu an BİZİM İÇİN GÖRÜNMEZDİR.

Şekil 4: Kohortların Toplam (Kümülatif) Satış Eğrisindeki Yavaşlama Şekil 5: BTYD (Ölene Kadar Satın Al) Modelinin Arka Plan Anatomisi Şekil 4'te bir grup müşterinin toplam satın alımlarının zamanla nasıl büküldüğünü, yavaşladığını görüyoruz. Eğer kimse ölmese, bu çizgi doğrusal (dümdüz) uzardı. Ancak Şekil 5 bize bu bükülmenin arkasındaki gizli nedeni gösterir: Şekil 5'te bireysel müşteriler (Cust 1, Cust 2, Cust 3) farklı eğimlerle (farklı satın alma hızlarıyla) alışveriş yapmaktadır. Cust 2 çok hızlı (dik eğimli) alırken erkenden 'ölür' (çizgisi kesilir). Cust 1 orta hızla alıp sonra ölür. Bu bireysel ölümlerin birleşimi, en üstteki (Total) kümülatif satış çizgisinin bükülmesine ve yavaşlamasına neden olur. İşte olasılık modelleri, bu bireysel ölümleri tahmin etmeye yarar. 3.2. Yüzeysel Geçilen Modellerin Dev İnternet Araştırması (Pareto/NBD ve BG/NBD) Makalede isimleri geçip detayı verilmeyen bu modeller, veri biliminde CLV (Customer Lifetime Value) hesaplamının kalbidir. İnternet ve literatür araştırmamıza göre bu modellerin ardındaki (\mu)azzam teorik altyapı şöyledir:

1. Pareto/NBD (Negative Binomial Distribution) Modeli: 1987'de Schmittlein vd. tarafından yaratılan bu 'beygir gücü' model şunları varsayar:

- Satın alma hızı (λ) birey için sabittir (Poisson), ancak popülasyonda Gamma dağılımı ile değişir.
- Ölüm hızı (μ) birey için sabittir (Exponential), ancak popülasyonda Gamma dağılımı ile değişir. Bu iki Gamma'nın birleşimi Pareto (ikinci tür) dağılımını yaratır. Ancak modeli kurmak ve matematiğini çözmek aşırı zordur. Sadece üç veriye ihtiyaç duyar: RFM (Recency - Son alışveriş zamanı, Frequency - Alışveriş Sıklığı, Monetary - Ortalama Tutar).

2. BG/NBD (Beta-Geometric / NBD) Modeli: Fader ve Hardie'nin kendi geliştirdiği (2005) çok daha pratik bir modeldir. Pareto/NBD'deki 'Müşteri her an ölebilir' varsayımını değiştirip, 'Müşteri SADECE BİR SATIN ALMA YAPTIKTAN SONRA (işlem anında) ölebilir' varsayımını getirir. Ölüm anı Beta-Geometric dağılım ile modellenir. Matematiksel olarak Excel'de bile çözülecek kadar hafif, ama Pareto/NBD kadar güçlüdür.

4. Gözden Kaçan Çeyrek: Ayırık Sözleşmesiz (Discrete-Noncontractual) Ortamlar

Matrisin sol alt köşesi, işlemlerin sadece belirli zamanlarda olduğu ama üyeliğin iptal edilemediği durumlardır. (Örn: Lüks kruvaziyer gemisi turları, yıllık bağış kampanyaları). Şekil 6: Lüks Gemi Turları İçin Ayırık Zamanlı İşlem Ağacı (Binary String) Şekil 6, 1993'ten 1997'ye kadar lüks gemi turuna katılanların (Y=Yes, N=No veya 1 ve 0 şeklinde) nasıl devasa bir olasılık ağacına dönüştüğünü gösterir. Müşterinin işlem geçmişi (Örn: 10110) bir ikili koda (binary string) dönüşür. Analistin görevi, sondaki sıfırların (00) 'Ölmüş' bir müşteri mi, yoksa 'Ara vermiş' bir müşteri mi olduğunu tahmin etmektir. 4.1. İnternet Araştırması: BG/BB (Beta-Geometric / Beta-Binomial) Modeli Ayırık zaman için yazarların geliştirdiği BG/BB modeli internet araştırmamıza göre şu devasa matematiği kullanır: - Satın Alma Fazı: Sürekli zamandaki Poisson (NBD) yerine, burada Bernoulli denemeleri kullanılır. Müşteri her fırsatta (her yıl) bir para atar, tura gelirse gemi turuna katılır (Binomial). Bu ihtimal toplumda Beta dağılır (Beta-Binomial). - Ölüm Fazı: Müşteri her fırsatın sonunda ayrı bir para atar, yazı gelirse sistemi kalıcı olarak terk eder (Geometric). Bu ihtimal de toplumda Beta dağılır. Sonuçta BG/BB modeli, kocaman zaman aralıklarına sıkıştırılmış ayırık verilerde inanılmaz başarılı tahminler yapan bir devdir.

5. Sözleşmeli (Contractual) Çeyreklerin Yapısı ve Modelleri

Sözleşmeli ortamlarda (Abonelikler) ölüm nettir. Müşterinin ne zaman gideceğini tahmin etmek yerine, 'ne kadar süre daha bizimle kalacak?' (Expected Residual Lifetime) sorusu sorulur. Klasik Lojistik Regresyon veya Karar Ağaçları bu uzun vadeli ömür tahminini yapamaz, sadece 'Gelecek ay gider mi?' (1-0) tahmini yapar. Matrisin Sağ Alt Köşesi

(Discrete-Contractual / Dergi Abonelikleri): Bu grupta yazarların bir önceki makalesinde işlenen sBG (shifted-Beta-Geometric) modeli kullanılır. Temeli, ayrılma ihtimali (θ) sabit olan müşterilerin oluşturduğu Beta heterojenliğidir. Matrisin Sağ Üst Köşesi (Continuous-Contractual / Cep Telefonu, Kredi Kartı): Müşteri istediği saniye aboneliği (sözleşmeyi) sonlandırabilir. Bu grupta sBG'nin sürekli zamanlı versiyonu olan Exponential-Gamma (EG) veya Weibull-Gamma (WG) modelleri kullanılır. - EG (Exponential-Gamma): Ölüm tehlikesi (Hazard Rate) birey için sabittir (Exponential), toplumda Gamma dağılır. - WG (Weibull-Gamma): Eğer yöneticiler 'Müşterinin zamanla bana olan sadakati artar veya azalır' diyorsa, birey bazında tehlike oranının zamanla değişmesine izin veren Weibull dağılımı işin içine katılır. Araştırmalar göstermiştir ki, Weibull modeli bazen bireysel düzeyde Pozitif Süre Bağımlılığı (zamanla sıkılan/terk etme ihtimali ARTAN müşteriler) olduğunu, ancak Gamma (heterojenlik) sebebiyle genel toplumda terk oranının DÜŞÜYOR gibi (Heterojenlik Yanılsaması) göründüğünü matematiksel olarak kanıtlar.

6. Nihai Çıkarım: Olasılık Modelleri Neden Paha Biçilemez?

Makalenin ana fikri şudur: Big Data ve karmaşık Makine Öğrenmesi (Neural Networks, SVM) dünyasında bile, insan davranışının temellerine (Para atışı, Poisson rastlantısallığı) dayanan Olasılıksal Modellerin (Pareto/NBD, BG/NBD, sBG) yerini hiçbir şey tutamaz. Çünkü regresyonlar sadece 'A değişkeni B'yi nasıl etkiler?' (Covariates) sorusunu çözerken; Olasılık modelleri 'Elimizde sadece müşterinin alışveriş sıklığı ve zamanı (RFM) varken onun gelecekteki CLV'si (Müşteri Yaşam Boyu Değeri) nedir?' gibi stratejik ve milyar dolarlık soruları Bayes Teoreminin gücüyle çözer. Bugünün modern Veri Analitiği ekiplerinin (Data Science) geleneksel eğri uydurma yöntemlerini derhal terk edip, firmalarının doğasına göre (Continuous/Discrete - Contractual/Noncontractual) uygun BTYD (Buy Till You Die) olasılık modelini kurmaları hayati bir bilimsel zorunluluktur.

7. RFM VE İZO-DEĞER EĞRİLERİYLE CLV OPTİMİZASYONU

RFM and CLV:Using Iso-Value Curves for Customer Base Analysis

1. Giriş: RFM Skorlamasının Çöküşü ve Bilimsel Yeniden Doğuş

Müşteri İlişkileri Yönetimi (CRM) ve Doğrudan Pazarlama (Direct Marketing) disiplinleri, var oldukları günden bu yana her zaman müşterileri sınıflandırma ihtiyacı duy(\mu)ştur. Şirketler, kime katalog göndereceklerini, kime promosyon yapacaklarını belirlemek için onlarca yıldır çok basit, sezgisel bir sisteme güvenmişlerdir: RFM (Recency, Frequency, Monetary Value). Yani bir müşterinin en son ne zaman alışveriş yaptığı (Recency), ne kadar sıklıkla alışveriş yaptığı (Frequency) ve her alışverişte ortalama ne kadar para harcadığı (Monetary Value). Geleneksel RFM yaklaşımında yöneticiler, veritabanındaki tüm müşterileri bu üç değişkene göre sıralar, her birini %20'lik dilimlere böler ve her müşteriye 1 ile 5 arasında puanlar vererek (Örneğin 5-5-5 en iyi müşteri, 1-1-1 en kötü müşteri) segmentasyon yaparlar. Ancak Fader, Hardie ve Lee (2005) tarafından kaleme alınan bu devrim niteliğindeki makale, bu sezgisel ve ilkel 'Scoring (Puanlama)' modellerinin temellerine dinamit koyar. Regresyon temelli puanlama modelleri veya veri madenciliği araçları (Data Mining, Karar Ağaçları), sadece geçmiş veriyi ezberler ve bir adım sonrasını (Period 2) tahmin etmeye çalışır. Oysa bizim asıl amacımız, Müşteri Yaşam Boyu Değerini (CLV - Customer Lifetime Value), yani müşterinin tüm ömrü boyunca şirkete bırakacağı NET FİNANSAL DEĞERİ (gelecekteki nakit akışlarının bugünkü değeri) hesaplamaktır. İşte bu noktada yazarlar, geçmişte sadece bir 'sezgi' olarak kullanılan RFM metriklerinin, devasa Olasılık Kuramları (Probability Models) için aslında tek başına yeterli (Sufficient Statistics) olduğunu kanıtlarlar. Regresyonun çökmesinin nedeni, insan davranışının karmaşıklığını doğrusal bir çizgiye oturtmaya çalışmasıdır. Ancak insan doğası deterministik değil, stokastiktir (rastgelelik barındırır). Bir müşteri bu ay 3 kez alışveriş yapıp gelecek ay hiç yapmayabilir. Bu, onun öldüğü (şirketi terk ettiği) anlamına gelmez, sadece kendi içsel ortalaması (latent trait) etrafında rastgele dalgalanıyordur. İşte

bu makale, tüm bu stokastik yapıyı 'Eş-Değer Eğrileri (Iso-Value Curves)' adlı (\mu)azzam görsel formlarla haritalandırır.

2. İnsan Davranışının Ham Hali: Veri Neden Kendi Başına Yetersizdir?

Yazarlar, karmaşık olasılık kuramlarına girmeden önce okuyucuya çok temel bir problemi göstermek isterler: Sadece ham veriye (raw data) bakarak geleceği göremeyiz. CDNOW (eski bir online müzik perakendecisi) veri setini kullanarak 1997'nin ilk çeyreğinde sisteme katılan 23.570 müşterinin tüm hareketlerini analiz ederler. İlk 39 haftada x kere alışveriş yapmış ve son alışverişini tx zamanında yapmış müşterileri gruplarlar. Sonra da bu grupların SONRAKİ 39 HAFTADA (gelecekte) ne kadar harcama yaptıklarına bakarlar. Şekil 1: 40-78. Haftalar Arasındaki Ortalama Harcamanın, Geçmiş Recency ve Frequency Verilerine Göre 3 Boyutlu Ham Dağılımı Şekil 1'e baktığınızda devasa bir dağınıklık görürsünüz. Z eksen (yukarı doğru uzanan dikitler) müşterilerin gelecekteki harcamasıdır. X ekseninde Frekans (Sıklık), Y ekseninde ise Yenilik (Recency) vardır. Teorik olarak, arka sağ köşede olanların (hem en son dün alışveriş yapmış hem de 10 kere alışveriş yapmış olanların) en büyük dikiti oluşturmaları beklenir. Evet, genel bir eğilim olarak bu doğrudur. Ancak grafik sivri uçlarla, anlamsız vadilerle ve korkunç boşluklarla (sparsity) doludur. Sadece 3 kere alışveriş yapmış bir adamın dikiti, 5 kere yapmış adamdan aniden daha yüksek çıkabilmektedir. Bunun sebebi, veri setinde bazı kutularda sadece 1-2 insanın tesadüfen çok harcamış olmasıdır. Ham veri böyledir; gürültülüdür, yalan söyler ve pürüzlüdür. Şekil 2: Şekil 1'in 30.000 Feetten Görünümü (Contour Plot) ve Titrek Eş-Değerler Eğer Şekil 1'e tam yukarıdan bakarsak Şekil 2'yi elde ederiz. Bu grafik bir Contour Plot (Eş Yükselti Eğrisi) haritasıdır. Çizgiler üzerindeki sayılar (50, 100, 200 vb.), gelecekte tam olarak o kadar dolar harcayacak insanları birbirine bağlar. Ancak çizgiler kırık, titrek ve düzensizdir. Şirket yönetimine böyle titrek bir harita verip 'İşte müşterilerinizin geleceği' diyemezsiniz. Bize evrensel bir doğa kanunu, pürüzsüz bir denklem seti gerekir. Şekil 3: Olasılık Teorisinin Ulaşmayı Hedeflediği Mükemmel (Hipotez Edilen) Iso-Value Eğrileri İşte yazarların tüm bu matematiksel inşaatı yapma sebebi Şekil 3'te gizlidir. Şekil 3, bir bilim insanının hayalindeki pürüzsüz 'Iso-Value (Eş-Değer)' haritasıdır. Şirkete 'Orta (Medium)' düzeyde para bırakacak olan müşteriler, o pürüzsüz yay üzerinde toplanmalıdır. Bu yay bize çok derin bir felsefe söyler: Bir müşterinin Recency'si çok düşük (çok eskiden almış) ama Frequency'si çok yüksekse, bu müşteri, Recency'si çok yüksek (dün almış) ama Frequency'si düşük olan taze bir müşteri

ile TAMAMEN AYNI CLV DEĞERİNE SAHİP OLABİLİR. İkisi de aynı yayın üstündedir! İşte bu, geleneksel puanlama modellerinin asla göremeyeceği bir takastır (Trade-off).

3. Matematiğin Derinlikleri: İşlem Akışı (DET) ve Parasal Değerin Bağımsızlığı

Fader ve Hardie, Müşteri Yaşam Boyu Değerini (CLV) hesaplarırken problemi iki büyük stokastik okyanusa bölerler. Çünkü bir müşterinin ne kadar sıklıkla alışveriş yaptığı ile o alışverişte ne kadar harcadığı birbirinden BAĞIMSIZ süreçlerdir. Denklem 1 bu ayrımı resmileştirir: $CLV = \text{Kar Marjı (Margin)} \times \text{İşlem Başına Gelir (Revenue/Transaction)} \times \text{İndirgenmiş Beklenen İşlemler (DET)}$ Bu denklemdeki Kar Marjı (%30 vb.) sabit kabul edilir. Geriye hesaplanması gereken iki canavar kalır: 1) İnsanlar gelecekte toplam kaç kere daha alışveriş yapacak? (DET) ve 2) Her alışverişte ortalama kaç para harcayacaklar? (Monetary Value). 3.1. İlk Canavar: DET ve Pareto/NBD Modeli Müşterilerin gelecekte yapacağı işlemlerin (finansal faiz oranıyla bugüne çekilmiş) sayısı olan DET (Discounted Expected Transactions), efsanevi Pareto/NBD (Negative Binomial Distribution) modeliyle çözülür. Modelin temel varoluş sebebi şudur: CDNOW gibi e-ticaret siteleri 'Sözleşmesiz (Noncontractual)' ortamdır. Müşteri üyeliğini iptal etmez, hesabı kapatmaz. Sadece alışveriş yapmayı bırakır. Müşteri 'Öldü mü (Churn mü oldu)?' yoksa sadece 'Ara mı verdi?' asla bilemeyiz. Model bunu iki zıt güçle hesaplar: - Poisson Alışveriş Süreci: Müşteri 'Hayattayken (Active)' rastgele ama kendi doğasına uygun bir sıklıkla (λ) alışveriş yapar. Kimi haftada bir alır, kimi yılda bir. - Üstel (Exponential) Ölüm Süreci: Müşteri her an, tamamen rastgele bir sürede (μ) aniden firmayı terk edebilir. Üstelik bu λ ve μ değerleri, toplum içinde sabit değildir, Gamma dağılımlarıyla her insanda farklılık gösterir. Yazarlar, geçmişte çok zor hesaplanan bu modeli alıp Denklem 2'ye (Gauss hipergeometrik fonksiyonlarına - Confluent Hypergeometric Function) entegre ederek, geleceği sonsuz ufuk (infinite horizon) üzerinden hesaplarlar. Yani her an için ayrı ayrı integral almak yerine, tüm geleceği tek bir devasa denklemle finansal şimdiki zamana (Present Value) çekerler.

4. İkinci Canavar: Parasal Değerin (Monetary Value) Gamma-Gamma Kuramıyla İfşası

İşlem sayısını (DET) bulduk. Şimdi her işlemde kaç para harcanacağını bulmalıyız. Ancak yazarlar en başta devasa bir iddia atar: 'Bir adamın çok sık alışveriş yapması, onun az veya

çok para harcayacağı anlamına gelmez. Frekans (X) ile Parasal Değer (M) birbirinden bağımsızdır!' Şekil 4: İşlem Sayısına Göre Ortalama İşlem Değerinin Kutu Grafiği (Box-and-Whisker) Dağılımı Bunu ispatlamak için Şekil 4'ü çizerler. 1 kere, 2 kere veya 7+ kere alışveriş yapanların her bir işlemde harcadıkları ortalama tutarların kutu grafiğini koyarlar. Çıkan sonuç inanılmazdır: Kutu boyları, medyan çizgileri ve dağılım çeyreklikleri neredeyse birebir aynı hizada ilerlemektedir. Evet, ufak tefek aykırı değerler (yukarı fırlayan yıldızlar) vardır ama korelasyon %6 (0.06) civarında, yani anlamsızdır. Bağımsızlık ispatlanmıştır! 4.1. İnternet Araştırması: Gamma-Gamma Modelinin "Ortalamaya Çekme" Felsefesi Sadece 'Ortalama para bağımsızdır' demek yetmez, bu paranın miktarını nasıl tahmin edeceğimiz sorunu başlar. Makalenin derinlemesine girmeyip formüllerini verdiği Gamma-Gamma modeli, günümüzdeki (PyMC, Lifetimes vb.) Makine Öğrenmesi dünyasının temelidir. Modelin mantığı, 'Ortalamaya Regresyon (Regression to the Mean)' felsefesine dayanır. Düşünün ki Ali adında biri sitenize geldi, ilk ve tek alışverişinde 500 dolarlık devasa bir paket aldı. Siz bu adama bakıp, 'Oooo bu adamın E(M) (Beklenen Ortalama Değeri) 500 dolardır, adam her geldiğinde 500 dolar bırakacak' diyebilir misiniz? HAYIR! Olasılık modelleyicileri (Bayesyen kuramcılar) der ki: 'Ali şans eseri 500 harcamış olabilir, bizim toplu(\mu)(\mu)zun genel harcama ortalaması 35 dolardır. Ben Ali'ye inanmıyorum, onun değerini 35 dolara doğru GERİ ÇEKECEĞİM.' Peki Ali ne yaparsa sistem ona inanır? Eğer Ali 20 KERE alışveriş yapar ve her seferinde 500 dolar harcarsa, sistem der ki: 'Tamam, elimde yeterli kanıt (Frekans) var. Ali tesadüf eseri değil, doğası gereği zengin. Artık onun E(M) değerini toplu(\mu)n 35 dolarına çekmeyeceğim, kendi gerçek değerine (500) yakın bırakacağım.' İşte Denklem 4'teki 'Ağırlıklandırılmış Ortalama (Weighted Average)' formülü tam olarak bunu yapar. İki Gamma dağılımı (Biri kişinin kendi içindeki dalgalanmaları, diğeri toplumdaki zengin/fakir heterojenliğini belirler) birbiriyle savaşarak kişinin GERÇEK değerini ortaya çıkarır. Şekil 7: Gözlemlenen (Gerçek) Harcama Dağılımı (Düz Çizgi) ve Gamma-Gamma Modelinin Teorik Tahmini (Kesik Çizgi) Şekil 7 bu teorinin gerçek verideki ispatıdır. Çoğu alışverişin düşük meblağlı (15-20\$ bandında) olduğu, sağa doğru uzunca uzanan çarpık (skewed) harcama verisini Normal Dağılım (Çan Eğrisi) asla anlayamazdı. Ancak Gamma-Gamma modeli (kesik çizgi), bu asimetrik davranışı o kadar kusursuz kopyalar ki, eğriler birbirinin üstüne biner.

5. Teorinin Ateşle İmtihani: Doğrulama (Validation) Testleri

Olasılık modelleyicileri sadece denklemleri yazıp bırakmazlar. Veri setini ilk 39 hafta (Eğitim/Calibration) ve son 39 hafta (Test/Holdout) olarak ikiye bölerler. Tüm amaç, ilk 39 haftaya bakarak eğittikleri modelin, GELECEKTEKİ (son 39 hafta) satın almaları bilip bilemeyeceğini görmektir. Şekil 5: Toplam Kümülatif İşlemlerin Zaman İçinde Takibi Şekil 6: 40-78. Haftalar Arasındaki Gelecekteki Koşullu Satın Alma Beklentileri Şekil 5, sistemin genel başarısıdır. Düz çizgi (Gerçek Satışlar) ile kesik çizgi (Pareto/NBD Tahmini) 78. haftaya kadar ayrılmaz bir ikili gibi tırmanır. Toplam satışları bilmek kolaydır. Asıl zor olan BİREYLERİ bilmektir. Şekil 6 bunu yapar: X ekseninde 'İlk 39 haftada X kere alanlar' vardır. Y ekseninde ise 'Bu adamlar İKİNCİ 39 HAFTADA kaç kere aldı?' sorusu yanıtlanır. Modelin (Yıldızlı çizgi) gerçek dünyayı (Düz çizgi) kopyalama yeteneği korkutucudur. İlk başta 7+ kez alan sadıklar, gelecekte de 6'dan fazla almıştır ve model bunu santimi santimine bilmiştir. Şekil 8: Parasal Değerin Koşullu Beklentileri (Hem İşlem Hem Para Birleşimi) Şekil 8 ise zurnanın zırt dediği, matematiğin zirve yaptığı noktadır. Pareto/NBD (İşlem tahmini) ile Gamma-Gamma (Para tahmini) çarpılarak, müşterilerin gelecekteki TOPLAM HARCAMALARI hesaplanır. Gerçek harcama ile beklenen harcama eğrileri neredeyse birbirine sarılarak hareket eder. Model rüştünü ispatlamıştır; artık CLV şelalelerini çizmeye hazırız.

6. Nihai Hedef: Iso-Value Şelaleleri ve Artan Sıklık Paradoksu

Modelimiz doğrulanmış bir şekilde artık 78 haftalık tüm veriyi yutarak CLV haritalarını çizer. Şekil 9: İndirgenmiş İşlemlerin (DET) Recency ve Frequency Fonksiyonu Olarak 3 Boyutlu Şelale Grafiği Şekil 10: Şekil 9'un Kuşbakışı Tepeden Görünümü (Iso-Value Eğrilerinin Gerçeğe Dönüşmesi) Şekil 9'daki 'Şelale', Şekil 1'deki o dağınık ve çirkin ham verinin Bayesyen matematikle nasıl pürüzsüz bir şahesere dönüştüğünün kanıtıdır. Yüksek Frekans ve Yüksek Yenilik zirveleri oluşturur. Şekil 10 ise o zirvenin haritasıdır (Eş-Değer çizgileri). Ancak Şekil 10'da ortalığı karıştıran bir anomali vardır: Sol alt köşede çizgiler geriye doğru (sağa) bükülmektedir! Yani, Frekansı 7 olan (sık alan) bir adamın DET değeri (2), Frekansı 1 olan adamla aynı değere sahiptir. Bu nasıl bir saçmalıktır? Çok alışveriş yapan adam nasıl az alışveriş yapan adamla aynı geleceğe (düşük CLV) sahip olabilir? Şekil 11: Olasılık Teorisinin En Büyük Çıkarımı: Artan Sıklık Paradoksu (The Increasing Frequency Paradox) İşte bu bükülmenin felsefesi Şekil 11'de yatar. Bütün yöneticiler bu tuzağa düşer. Şekil 11'de Customer A toplam 4 alışveriş yapmış, seyreker (düşük frekans) bir adamdır. Customer B ise toplam 8 alışveriş yapmış, çılgın gibi her gün

bir şeyler almış (yüksek frekans) bir adamdır. Ancak İKİSİ DE 30 hafta önce aniden alışverişi kesmiştir (Aynı düşük Recency). Olasılık kuramı der ki: Müşteri B her gün alışveriş yaparken aniden durduysa, BÜYÜK BİR SORUN VARDIR. Bu adam kesinlikle rakip firmaya geçmiştir, yani 'ÖLMÜŞTÜR (Churn)'. Oysa Müşteri A zaten normalde de aylarca uğramayan, doğası seyrek bir adamdır. 30 haftadır gelmiyor oluşu onun öldüğünü değil, döngüsünün yavaş olduğunu gösterir. Yani Müşteri A %80 HALA HAYATTADIR. Bu yüzden Müşteri A'nın gelecekteki CLV'si, çok alışveriş yapan Müşteri B'den DAHA YÜKSEK çıkar. İşte 'Artan Sıklık Paradoksu' budur. Klasik puanlama modelleri Müşteri B'ye 5 yıldız verip promosyon yağdırırken parayı çöpe atarlar, oysa olasılık modeli gerçeği çoktan deşifre etmiştir! Şekil 12: Ortalamaya Regresyon ve DET Çoklayıcıları (Multipliers) Şekil 12, Gamma-Gamma'daki o 'Sana inanmıyorum, ortalamaya çekeceğim' felsefesinin grafiğidir. X eksenindeki işlem sayısı (Frekans) 1-2 civarındayken, 50 dolar (Kesik çizgi) veya 20 dolar (Noktalı çizgi) harcayan herkes sistem tarafından zorla 35 dolarlık (Düz çizgi) genel ortalamaya doğru bastırılır. Ancak adam 10-14 kere alışveriş yapmaya devam edip istikrarını kanıtladığında, kesik çizgiler yukarı (gerçek 50 dolara), noktalı çizgiler aşağı (gerçek 20 dolara) açılmaya, kendi bağımsız karakterlerine doğru yayılmaya başlarlar.

7. Dev Birleşim: Farklı Fiyatlar İçin Devasa CLV Haritaları

Şekil 13: 20\$ ve 50\$ Ortalama Tutar İçin Eş-Değer (Iso-Value) CLV Eğrileri Şekil 13, tüm makalenin final ürünüdür. İşlem Sayısı (Pareto/NBD), İskonto (Paranın Zaman Değeri), Kâr Marjı ve Parasal Değer (Gamma-Gamma) her şeyin tek potada eritildiği Şelale ve Eş-Değer haritalarıdır. 20 dolarlık adamla 50 dolarlık adamın şelaleleri (Z eksenindeki zirveleri) farklıdır (Biri 200'de diğeri 600 dolarda zirve yapar). Alt kısımdaki Contour plotlarda, o meşhur paradoks gereği çizgilerin geriye doğru büküldüğünü net bir şekilde görebilirsiniz. Şekil 14: 78 Haftalık Pürüzsüz Iso-Value Uzayında Gerçek Müşteri Dağılımının İnşası Son Şekil 14, teoriyi gerçeklikle çarpıştırır. CDNOW şirketindeki 11.506 tekrarlı müşterinin ham dağılımını, modelin pürüzsüz Iso-Value uzayının üzerine bir matris gibi oturtur. Yöneticiler, bu haritaya bakarak hangi müşteri kümesine ne kadar yatırım yapacaklarını ('Return on Investment') kusursuzca görebilirler.

8. Bilimsel Çıkarımlar ve Kapanış

Peter Fader ve ekibi bu eserleriyle şunu ispatlamıştır: Veri madenciliği ve 'kara kutu' algoritmalarının aksine, insan doğasını anlayan olasılık kuramları şirketlere milyarlarca

dolar kazandırabilir. RFM verileri, sadece müşteriye geçmişine göre dizeleyen ilkel bir puan cetveli değildir; eğer Bayesyen olasılık kuramlarıyla işlenirlerse, müşterinin 5 yıl sonra şirkete bırakacağı dolar bazındaki net CLV'yi (Yaşam Boyu Değeri) kusursuzca hesaplayacak birer 'Sufficient Statistic (Yeterli İstatistik)'tirler. Artan Sıklık Paradoksunun keşfi ise, CRM dünyasında bir aydınlanma devrimidir.

8. PU LEARNING İLE ZAMANA DUYARLI CHURN ALGORİTMALARI

Time-sensitive Customer Churn Prediction based on PU Learning

1. Problemin Tanımı: Müşteri Kaybı (Churn) Nedir?

Modern internet şirketleri için en büyük zorluklardan biri müşteri kaybıdır (customer churn). Müşteri kaybı, bir kullanıcının şirketin hizmetlerini kullanmayı bırakması anlamına gelir. Şirketler, hangi müşterilerin ayrılma eğiliminde olduğunu önceden tahmin edip onlara özel kampanyalar (indirimler, promosyonlar) sunarak bu kaybı engellemeye çalışırlar. Bunu yapmak için şirketler makine öğrenmesi modelleri kullanır. Ancak bu modellerin eğitilmesi için veri setinde iki tür müşteriye ihtiyaç vardır: • Pozitif Örnekler ($y=1$): Uygulamayı kullanmayı bırakan (churn olan) müşteriler. • Negatif Örnekler ($y=0$): Uygulamayı aktif olarak kullanmaya devam eden müşteriler.

2. Geleneksel Yöntemlerin Sıkıntıları Nelerdir?

Geleneksel makine öğrenmesi algoritmaları (Karar Ağaçları, Destek Vektör Makineleri, Lojistik Regresyon vb.) "Gözetimli Öğrenme" (Supervised Learning) prensibiyle çalışır. Yani modelin öğrenebilmesi için hem pozitif hem de negatif örneklerin kesin olarak bilinmesi gerekir. Ancak gerçek hayatta, özellikle internet şirketlerinde büyük bir sorun vardır: Bir müşterinin kesin olarak "uygulamayı terk ettiğini" (pozitif örnek) anlamak için uzun bir süre geçmesi gerekir. Bu süreye "Churn Periyodu (CP)" denir ve Alipay gibi şirketlerde bu genellikle 3 ile 6 ay arasındadır. Sorun: Eğer bir modeli eğitmek için 6 ay beklemek zorundaysanız, eğiteceğiniz model 6 ay önceki kullanıcı davranışlarına göre eğitilmiş olacaktır. İnternet dünyası çok hızlı değiştiği için, 6 ay önceki verilerle eğitilmiş bir model günümüzde kullanıldığında geçerliliğini yitirmiş, "bayatlamış" olacaktır. Şirketlerin, çok daha güncel verilerle ve aylarca beklemeden modeli eğitmeye ihtiyacı vardır.

3. Çözüm: PU Learning ve TCCP Çerçevesi

Makale bu bayat veri sorununu çözmek için TCCP (Time-sensitive Customer Churn Prediction - Zaman Duyarlı Müşteri Kaybı Tahmini) adında yeni bir mimari öneriyor. Bu mimarinin kalbinde PU Learning (Positive and Unlabeled Learning) adı verilen teknik yatıyor. PU Learning (Positive and Unlabeled Learning) Nedir? PU Learning, elinizde sadece kesin olarak bildiğiniz "Pozitif" örneklerin olduğu, geri kalan tüm verinin ise ne olduğunun bilinmediği ("Etiketlenmemiş" - Unlabeled) durumlarda kullanılan bir yarı-gözetimli makine öğrenmesi yöntemidir. TCCP çerçevesinde bu durum şu şekilde uygulanır: • Kısa bir "Gözlem Periyodu" (OP - Observation Period) belirlenir (Örneğin sadece 15 gün). • Bu 15 gün içinde uygulamaya giriş yapan müşteriler kesin olarak "Aktif" (Pozitif) kabul edilir. • 15 gün içinde giriş yapmayan müşterilerin durumu ise "Belirsiz" (Etiketlenmemiş / Unlabeled) olarak kabul edilir. Çünkü bu kişiler belki 20. gün girecekler (yani aslında aktifler), belki de uygulamayı tamamen sildiler (yani churn oldular). Bunu 6 ay beklemeden bilemeyiz. İşte PU Learning, bu 6 ayı beklemeden, sadece kesin aktif olanlar ve geri kalan "belirsiz" kitle üzerinden modeli eğitmeyi başarır.

4. TCCP Çerçevesinin Adım Adım İşleyişi

Aşağıdaki görsel, önerilen TCCP sisteminin nasıl çalıştığını özetlemektedir: Figure 1: Zaman Duyarlı Müşteri Kaybı Tahmini (TCCP) Çerçevesi İşlem Akışı Bu diyagram, ham veriden (Raw data) yola çıkarak müşteri kaybını tahmin eden nihai sınıflandırıcının (Build final classifier) nasıl eğitildiğini özetlemektedir. Sistem öncelikle kısa bir Gözlem Periyodu (Set OP) belirler ve bu süre zarfında hem uygulamayı kullanan Kesin Pozitif (P) örnekleri hem de durumu henüz bilinmeyen Etiketlenmemiş (U) örnekleri ayırıştırır. Aynı anda ham veri kullanılarak müşterilerin özellikleri çıkartılır (Feature Engineering). Kesik çizgilerle belirtilen "PU Learning by Weighting Samples" (Örnekleri Ağırlıklandırarak PU Öğrenme) aşaması sistemin merkezidir: Burada önce kaba bir sınıflandırıcı () oluşturulur ve toplam veri içindeki gerçek pozitif oranı () tahmin edilir. Ardından, belirsiz olan () örnekler kopyalanıp bunlara lojistik regresyon olasılıklarına göre hem pozitif hem de negatifmiş gibi ağırlıklar atanır (Weight samples). Son adımda ise oluşturulan bu zenginleştirilmiş veri seti ile Dağıtık Çarpanlara Ayırma Makineleri kullanılarak nihai ve en hassas müşteri kaybı tahmin modeli () eğitilmiş olur. Mimari temel olarak 3 aşamadan oluşur: Adım 1: Özellik Mühendisliği (Feature Engineering) Modelin müşterileri tanıyabilmesi için onlara ait özelliklerin (verilerin) matematiksel olarak ifade edilmesi gerekir. Makale 3 tip özellik kullanır:

1. Statik Profiller: Müşterinin yaşı, cinsiyeti, yaşadığı şehir, kayıt tarihi, üyelik seviyesi vb. sabit veriler.

2. Dinamik Tercihler: Müşterinin son zamanlardaki davranışları. Örneğin; son 7 gündeki uygulamaya giriş sayısı, son 15 gündeki harcama miktarı, son 30 gündeki tıklama sayıları gibi değişken veriler.

3. Çapraz Özellikler (Cross Features): Statik ve dinamik özelliklerin birleştirilmesiyle elde edilen yeni metrikler. Örneğin "Yaş" ve "Giriş Sayısı" çarpılarak, belirli yaş gruplarının giriş alışkanlıkları modele tanıtılır.

Adım 2: Örneklerin Ağırlıklandırılması (PU Learning by Weighting Samples) Bu aşama TCCP'nin en kritik noktasıdır. Belirsiz olan veriler modele nasıl öğretilir?

1. Lojistik Regresyon ile Başlangıç (Approximate Classifier): İlk olarak Lojistik Regresyon algoritması kullanılarak tüm veri setine kaba bir sınıflandırma yapılır. Bu sayede belirsiz (unlabeled) gruptaki her bir müşterinin "pozitif olma olasılığı" 0 ile 1 arasında bir değer olarak hesaplanır.

2. Tahmini Sabit (c) Hesaplanması: Toplam veri havuzu içerisindeki gerçek pozitif müşterilerin oranı (c) istatistiksel olarak tahmin edilir.

3. Ağırlıklandırma Sistemi:

Kesin pozitif olan (uygulamaya giren) müşterilere doğrudan "1" ağırlığı (tam güven) verilir. Etiketlenmemiş (belirsiz) her bir müşteri sanal olarak kopyalanarak ikiye çoğaltılır. Bu kopyalardan birine, Lojistik Regresyonun bulduğu olasılığa göre "pozitifmiş gibi" bir ağırlık verilir. Diğer kopyaya ise "negatifmiş gibi" ($1 - \text{pozitif ağırlık}$) bir ağırlık verilir. Böylece model, belirsiz müşterilerin özelliklerine bakarak onlara kısmi ihtimaller tanımış olur ve kesin bir karara varmadan öğrenmeyi sürdürür. Adım 3: Final Sınıflandırıcının Eğitilmesi

(Distributed Factorization Machines) Ağırlıklar belirlendikten sonra, makine öğrenmesi dünyasında çok büyük ve seyrek (sparse) veri setleri için özel olarak geliştirilmiş olan Factorization Machines (FM) - Çarpanlara Ayırma Makineleri algoritması devreye girer. Neden Distributed (Dağıtık)? Çalışmada kullanılan Alipay veri seti 200 milyon kullanıcıya ait milyarlarca özellik satırı barındırır. Bu kadar büyük bir veri ("Big Data"), tek bir bilgisayarın belleğine veya işlemcisine sığmaz. Bu yüzden veriler ve model parametreleri birçok bilgisayara (sunucuya) bölünür ve paralel olarak eğitilir. Buna Distributed FM denir.

5. Deneyler ve Çıkan Sonuçlar

Makalenin yazarları, sistemi dünyanın en büyük ödeme platformlarından biri olan Alipay.com'un gerçek verileri (200 milyon müşteri) üzerinde test etmişlerdir. Deneyde Gözlem Periyodu (OP) 3 gün, 7 gün, 15 gün, 30 gün, 60 gün ve 90 gün olarak değiştirilerek sonuçlara bakılmıştır. Karşılaştırılan Modeller (Baselines) TCCP'nin başarısını ölçmek için şu yöntemlerle kıyaslanmıştır: • Kural Tabanlı Yöntemler: "Müşteri son L gündür girmiyorsa churn olur" (Recency) veya "Müşteri D günde M kereden az girdiyse churn olur" (Frequency) gibi basit kurallar. • Geleneksel Gözetimli Öğrenme: Klasik Lojistik Regresyon ve standart FM algoritmaları. Kıyaslama Sonuçları TCCP, tüm eski ve kural tabanlı sistemleri açık ara farkla (örneğin kural tabanlılara göre %23 daha iyi AUC skoru ile) geride bırakmıştır. En İlginç Bulgu: OP süresi 15 gün olarak ayarlandığında model en yüksek başarıyı elde etmiştir. Eğer süre çok kısa tutulursa (ör: 3 gün) model yeterince müşteri hareketi göremediği için başarısız olmaktadır. Eğer süre çok uzun tutulursa (ör: 60 gün), veri "bayatladığı" için modelin tahmini günümüzü yansıtamamakta ve yine başarısız olmaktadır.

6. Sonuç ve Çıkarım

Geleneksel müşteri kaybı tahmin modelleri verinin aylar sonra kesinleşmesini beklediği için şirketleri geri dönüşü olmayan kayıplara uğratabilir ve yeni veri kalıplarını yakalayamaz. Özetle bu makaleden çıkarılacak temel sonuç şudur: Etiketlenmemiş "belirsiz" devasa veriyi bir kayıp veya engel olarak görmek yerine, PU Learning gibi yarı-gözetimli sistemlerle avantaja çevirmek mümkündür. TCCP mimarisi sayesinde, henüz müşterinin durumu kesinleşmeden bile davranışlarından elde edilen anlık ipuçlarıyla çok daha hızlı, güncel ve yüksek doğruluk oranlarına sahip tahminleme sistemleri kurulabileceği endüstriyel ölçekte (200 milyon kişi) ispatlanmıştır.

“COUNTING YOUR CUSTOMERS” THE EASY WAY AN ALTERNATIVE.DOCX

“Counting Your Customers” the Easy Way: An Alternative to the Pareto/NBD Model

1. Olasılık Kuramlarının Çatışması: Pareto/NBD'nin Zorlukları ve Yeni Bir Çağ

Müşteri İlişkileri Yönetiminde (CRM) gelecekteki satın almaları tahmin etmek için yıllarca veri madenciliği ve lojistik regresyonlar kullanıldı. Ancak bu deterministik modeller, insan doğasının rastgeleliğini (stokastik yapısını) asla yakalayamadı. Bu açığı kapatmak için 1987 yılında Schmittlein vd. tarafından yaratılan Pareto/NBD modeli, 'Ölene Kadar Satın Al (Buy Till You Die - BTYD)' felsefesiyle veri biliminde bir devrim yarattı. Pareto/NBD kusursuz bir felsefeye sahipti: Müşteriler hayattayken kendi içsel hızlarında (Poisson) alışveriş yapar, ancak görünmeyen bir anda aniden şirketi terk edebilirlerdi (Exponential). Fakat ortada korkunç bir matematiksel bariyer vardı: Pareto/NBD, müşterinin 'her an' (Continuous Time) ölebileceğini varsayıyordu. Yani müşteri gece uyurken, tatildeyken, hatta firmayı aklından bile geçirmede rastgele bir saniyede ölebilirdi. Bu 'Sürekli Zamanlı Ölüm' varsayımı, denklemin içine Gaussian Hypergeometric Functions (Gauss Hipergeometrik Fonksiyonları) gibi çözülmesi neredeyse imkansız olan, devasa bilgisayar gücü gerektiren kompleks integralleri soktu. Model o kadar zordu ki, yıllarca sadece elit akademisyenler tarafından kullanılabilirdi, şirketler bu modeli hayata geçiremedi. İşte bu makale (Fader, Hardie ve Lee, 2005), bu matematiksel işkenceye son veren zekice bir psikolojik hile yapar: BG/NBD (Beta-Geometric / Negative Binomial Distribution) modeli. BG/NBD'nin arkasındaki o devasa felsefe şudur: 'İnsanlar gece uyurken bir firmayı terk etmeye karar vermezler. Bir müşteri, ANCAK BİR İŞLEM YAPTIKTAN SONRA (bir alışverişin hemen ardından) o firmadan ayrılıp ayrılmamaya karar verir!' Bu ufacık varsayım değişikliği (Sürekli zamandan Ayrık zamana geçiş), o korkunç Gauss fonksiyonlarını silip atar ve milyarlarca dolarlık CLV tahminlerini standart bir Excel tablosunda bile çözülebilir hale getirir.

2. Maksi(\mu)m Yoğunluk: Kuramın Temel Varsayımları ve Denklemlerin Anatomisi

Model, 5 temel matematiksel aksiyom üzerine kuruludur: Aksiyom 1 (İşlem Hızı - Poisson): Müşteri hayattayken yaptığı işlem sayısı, λ ($\backslash\lambda$) işlem hızına sahip bir Poisson sürecidir. Yani iki alışveriş arasındaki süre Üstel (Exponential) olarak dağılır. Denklem 1: $f(t_{-j} | t_{-j-1}; \lambda) = \lambda * e^{-\lambda(t_{-j} - t_{-j-1})}$. Aksiyom 2 (İşlem Heterojenliği - Gamma): Her müşterinin λ hızı aynı değildir. Kimi hızlı (büyük λ), kimi yavaştır. Toplumdaki bu hız farklılığı, r (şekil) ve α (ölçek) parametrelerine sahip bir Gamma dağılımı ile modellenir. Denklem 1'in ikinci kısmı: $f(\lambda | r, \alpha) = (\alpha^r * \lambda^{r-1} * e^{-\alpha\lambda}) / \Gamma(r)$. Aksiyom 3 (Ölüm Anı - Geometrik Dağılım - DEV DEĞİŞİKLİK): İşte Pareto/NBD'den ayrılan kırılma noktası. Müşteri her alışverişinden sonra cebinden görünmez bir para çıkarıp atar. Eğer 'Yazı (p)' gelirse sistemi terk eder (Dropout). Eğer 'Tura (1-p)' gelirse hayatta kalır ve bir sonraki alışverişe kadar bekler. Bu, Geometric (Geometrik) Dağılımdır. Denklem: $P(j. \text{ işlemden hemen sonra ölme}) = p * (1-p)^{j-1}$. Aksiyom 4 (Ölüm Heterojenliği - Beta): Toplumdaki herkesin cebindeki paranın hile oranı (p) aynı değildir. Kimi vefasızdır (p yüksektir), kimi çok sadıktır (p düşüktür). Toplumdaki bu vefasızlık/sadakat dağılımı, a ve b parametrelerine sahip Beta Dağılımı ile modellenir. Denklem 2: $f(p | a, b) = (p^{a-1} * (1-p)^{b-1}) / B(a, b)$. Aksiyom 5 (Bağımsızlık): İşlem hızı (λ) ile ölüm ihtimali (p) birbirinden bağımsızdır. 2.1. İnternet Araştırması: Hipergeometrik Fonksiyonların Yok Edilmesi Araştırmalarımıza göre, Pareto/NBD modelindeki o korkunç 'hipergeometrik fonksiyon', müşterinin alışveriş yapmadığı (susku) sürelerde her an ölebileceği varsayımından doğan bir integral karmaşasıydı. (Ölüm anının alışverişler arasına düşmesi). Ancak BG/NBD'de ölüm SADECE alışveriş noktasında (işlem anında) olduğu için, denklemler cebirsel olarak (\mu)azzam basitleşir. Veri bilimciler günümüzde (Python Lifetimes, PyMC gibi kütüphanelerde) Pareto/NBD yerine %90 oranında BG/NBD kullanmaktadır. Çünkü BG/NBD'nin 'Gradient'i (türevlenebilirliği) çok daha kolay hesaplanır, bu da büyük veri setlerinde (Big Data) optimizasyon (MLE - Maxi(\mu)m Likelihood Estimation) algoritmalarının haftalar yerine dakikalar içinde sonuç vermesini sağlar.

3. Kuramın Pratiğe Dönüşü: Excel'de Çözülen Dev İhtimal Uzaı

Şekil 1: BG/NBD Parametre Tahmini İçin Excel Çalışma Sayfasının Anatomisi ve Formüller Şekil 1, makalenin yazılış amacının tam bir özetidir: O kadar (\mu)azzam bir olasılık teorisi ki, süper bilgisayarlara gerek kalmadan Excel'de bile hesaplanabiliyor! Tablodaki A

sütunu (r , α , a , b) modelin o aradığımız 4 büyüklü parametresidir (Toplu(μ)n heterojenliği). G satırından aşağıya inenler ise bireysel müşterilerdir. Her müşteri için sadece 3 veri vardır: x (Frekans), t_x (Son alışveriş zamanı - Recency) ve T (Müşterinin toplam yaşam süresi). F, G, H, I sütunlarındaki o karmaşık logaritmik formüller (Örn: GAMMALN), BG/NBD modelinin Bireysel Olabilirlik (Individual Likelihood) fonksiyonudur (Denklem 6). E sütunu, bu 4 sütunun birleşiminden oluşan Log-Likelihood (LL) değeridir. Excel Solver, B5 hücresindeki (LL Toplamı: -9582.4) değeri maksimize yapmak (sıfıra en çok yaklaştırmak) için B1, B2, B3 ve B4 hücrelerindeki (r , α , a , b) değerleriyle saniyeler içinde binlerce kez oynar ve optimum toplumsal parametreleri bulur.

4. Modellerin Çarpışması: BG/NBD vs Pareto/NBD

Model teoride çok basittir, ancak pratikte Pareto/NBD gibi ağır bir modelin yerini tutabilecek midir? Yazarlar bunu kanıtlamak için acımasız bir test yaparlar. Veri setini bölerler ve her iki modelin de geleceği ne kadar iyi tahmin ettiğine bakarlar. Şekil 2: Tekrarlı İşlem Frekansının Tahmin Edilen vs Gerçek Değerleri Şekil 2, kalibrasyon (eğitim) dönemindeki modelin veriye oturma (fit) gücünü gösterir. Siyah çubuklar gerçek hayattaki müşterilerin sayısıdır (Örn: Hiç alışveriş yapmayanlar, 1 kere yapanlar). Gri çubuk BG/NBD, Beyaz çubuk Pareto/NBD'dir. İlk bakışta BG/NBD'nin (Gri) Pareto/NBD'ye (Beyaz) göre siyah çubuklara çok daha yakın olduğunu (özellikle 1 ve 2 alışveriş yapanlarda) görebilirsiniz. Chi-Square (Ki-Kare) uyum iyiliği testi de bunu kanıtlar: BG/NBD istatistiksel olarak geçmiş veriye çok daha kusursuz uymaktadır. Şekil 3: Koşullu Beklentiler (Geleceği Tahmin Gücü - 40-78. Haftalar) Şekil 3, gerçek testi temsil eder: Geleceği bilmek! X eksen, müşterilerin İLK 39 haftada kaç kere alışveriş yaptığıdır. Y eksen ise, bu adamların İKİNCİ 39 haftada (gelecekte) kaç kere alışveriş yapacaklarıdır. Düz çizgi gerçek hayattır. Yuvarlak işaretli çizgi BG/NBD, Yıldızlı çizgi Pareto/NBD'dir. Çizgiler birbirine o kadar yapışıktır ki ayırt etmek neredeyse imkansızdır. İki modelin de geleceği tahmin etme gücü (korelasyon) %99.6 oranında aynıdır. Üstelik BG/NBD, 'Sıfır Sınıfını (Hiç tekrar yapmayan dev kitleyi)' Pareto/NBD'den çok daha iyi tahmin etmiştir (Gerçek: 0.24, BG/NBD: 0.23, Pareto/NBD: 0.14).

5. Bilimsel Çıkarım: Basitliğin Zaferi

Bu makalenin felsefesi Ockham'ın Usturası (Occam's Razor) prensibinin veri bilimine yansımasıdır: 'Eğer iki model de aynı sonucu veriyorsa, basit olanı seçin'. Müşterinin gece

uyurken mi öldüğü (Pareto/NBD) yoksa alışveriş yaptıktan hemen sonra mı öldüğü (BG/NBD) sorusu, felsefi bir detaydan ibarettir. Ancak bu küçük detay, aylarca süren süper bilgisayar hesaplamalarını standart bir Excel tablosuna indirecek kadar devasa bir matematiksel devrim yaratmıştır. Bugünün modern analistleri, CLV ve churn tahminlerinde BG/NBD'yi birincil silah olarak kullanır. Çünkü BG/NBD, hem RFM verisinin gücünü kullanır, hem ortalamaya çekme (regression to the mean) yasalarıyla insan doğasının rastgeleliğini dizginler, hem de şirketlerin CRM departmanlarına saniyeler içinde çalıştırabilecekleri bir altyapı sunar.

9. EK BÖLÜM: MODELLERİN MAKİNE DAİRESİ - MONTE CARLO, MCMC VE HİYERARŞİK BAYES

Önceki bölümlerde modellerin matematiksel formülasyonlarını ve felsefi altyapılarını tartıştık. Ancak iş bu denklemleri (özellikle integral ve olasılık fonksiyonlarını) Python veya R gibi bir dilde çözmeye geldiğinde, geleneksel cebir tıkanır. Özellikle SBB (Logit-Normal) gibi eşlenik olmayan (non-conjugate) dağılımlar kullandığımızda ya da binlerce parametrelili Hiyerarşik Bayes modelleri kurduğumuzda, "kapalı formülü" (closed-form) bir çözüm bulmak imkansızdır. İşte modern veri bilimcilerin bu sistemleri gerçek hayatta çalıştırmalarını sağlayan "Makine Dairesi" algoritmaları:

9.1. Monte Carlo Simülasyonu: Rastgeleliğin Gücü ile İntegral Çözümü

Fizikçiler tarafından Manhattan Projesi (atom bombası) sırasında icat edilen Monte Carlo yöntemi, özünde çözilemeyen çok katlı deterministik integralleri, "rastgele sayılar (random sampling) üreterek" yaklaşık olarak çözme sanatıdır.

Müşteri yaşam boyu değeri (CLV) hesaplarken, genellikle arka planda devasa bir beklenti (Expectation) integrali vardır: $E[f(x)] = \int f(x) p(x) dx$ Eğer $p(x)$ (olasılık dağılımı) çok karmaşıksa, bu integrali elle çözemezsiniz. Monte Carlo'nun dehası şudur: İntegral almak yerine, $p(x)$ dağılımından bilgisayara 10.000 adet rastgele x sayısı (örneğin müşteri satın alma ihtimali) üretirsiniz. Sonra bu sayıları $f(x)$ fonksiyonuna koyup sadece aritmetik ortalamasını alırsınız (Büyük Sayılar Yasası). Yani karmaşık kalkülüs (Calculus), yerini ilkökul matematiğine (ortalama almaya) bırakır. Ancak bu, sadece $p(x)$ dağılımından rastgele sayı üretebiliyorsanız işe yarar.

9.2. Markov Chain Monte Carlo (MCMC): Arka Planın Karanlığını Aydınlatmak

Peki ya elimizdeki veri seti o kadar karmaşıksa (örneğin BG/BB modeline SBB korelasyonu eklediğimiz durumlar) veya verinin arka planındaki (posterior) dağılımın denklemini bile tam olarak bilmiyorsak, o dağılımdan nasıl rastgele sayı üreteceğiz?

İşte burada **Markov Chain Monte Carlo (MCMC)** devreye girer. MCMC, dağılımın tam şeklini bilmesek bile o dağılımdan örneklem çekebilmemizi (sampling) sağlayan olağanüstü bir keşiftir. "Markov Chain" (Markov Zinciri), ürettiğimiz her yeni sayının/örneklemin sadece bir önceki sayıya bağlı olduğu, "hafızasız" bir rastgele yürüyüş (random walk) sürecidir. İki efsanevi algoritma ile çalışır:

9.2.1. Metropolis-Hastings Algoritması

Metropolis-Hastings, model uzayında rastgele bir noktadan (örneğin rastgele bir λ ve μ değeri) başlar. Rastgele küçük bir adım atarak yeni bir parametre teklif eder (proposal). Eğer bu yeni parametreler, elimizdeki müşteri verisini (satın alma geçmişini) **daha iyi açıklıyorsa** (Likelihood daha yüksekse), bu adımı kesin kabul eder. Eğer daha kötü açıklıyorsa, hemen reddetmez; belli bir olasılıkla kabul eder. Bu sayede algoritma sadece en yüksek tepelerde (optimum noktalarda) sıkışıp kalmaz, tüm olasılık uzayını tarar. Yeterli sayıda (örneğin 20.000) adım atıldıktan sonra (burn-in periyodu bittiğinde), algoritmanın gezindiği yerler, aradığımız gerçek olasılık dağılımının ta kendisidir!

9.2.2. Gibbs Örneklemesi (Gibbs Sampling)

Eğer çok fazla parametreniz varsa (örneğin Hiyerarşik modellerde her bir müşteri için ayrı parametre hesaplarken parametre sayısı 100.000'i bulabilir), Metropolis-Hastings çok yavaşlar (Curse of Dimensionality - Boyutluluk Laneti). Gibbs Sampling, parametreleri hep birlikte rastgele değiştirmek yerine, her adımda "diğer tüm parametreleri sabit tutup, sadece bir parametreyi kendi koşullu dağılımından (conditional distribution)" güncelleyen çok daha akıllı bir yöntemdir. Günümüzde Bayesian CLV analizlerinin (özellikle PyMC veya Stan kütüphanelerinde) motoru Gibbs veya onun modern bir varyantı olan NUTS (No-U-Turn Sampler)'dır.

9.3. Hiyerarşik Bayes (Hierarchical Bayes - HB) Modelleri

Makalelerde Gamma veya Beta dağılımlarının, popülasyonun "heterojenliğini" modellemek için kullanıldığını (p ve θ değerlerinin dağılımı) görmüştük. Ancak klasik modeller (Pareto/NBD vb.), tüm müşterilerin aynı küresel (global) Gamma dağılımından geldiğini varsayar.

Gerçek dünyada, "Kurumsal Müşteriler (B2B)" ile "Bireysel Müşteriler (B2C)", veya "Yazlıkçılar" ile "Kışlıkçılar" aynı Gamma dağılımına uymaz. **Hiyerarşik Bayes (HB)**, parametrelerin de parametreleri olduğu katmanlı bir yapıdır. 1. En alt seviye: Bireysel müşterinin kendi satın alma hızı (λ_i). 2. Orta seviye: Müşterinin ait olduğu segmentin (örneğin B2B) Gamma dağılım parametreleri (α_{B2B} , β_{B2B}). 3. En üst seviye (Hyperparameters): Tüm segmentlerin bağlı olduğu ana dağılım (Hyper-prior).

Hiyerarşik Bayes'in çözümü matematiksel olarak analitik entegrasyonla (kalem kağıtla veya Gauss Hipergeometrik fonksiyonuyla) çözülemez. Çözümün tek yolu, yukarıda anlattığımız **MCMC (Gibbs Sampling)** algoritmalarıdır. MCMC sayesinde, bilgisayar her gece 50.000 iterasyon yaparak hiyerarşideki her müşterinin tam profilini çıkartır. Verisi az olan yeni müşteriler, hiyerarşideki üst grubun ortalamasına çekilirken (Shrinkage effect - Büzülme etkisi), verisi çok olan eski müşterilerin kaderini kendi geçmiş verileri tayin eder.

9.4. Maksimum Simüle Edilmiş Olabilirlik (Maximum Simulated Likelihood - MSL)

Customer-Base Analysis (BG/BB SBB uzantısı) makalesinde, MCMC'ye alternatif olarak MSL kullanılır. MSL, "Olabilirlik" (Likelihood) fonksiyonundaki çözülemeyen integralleri hesaplamak için Monte Carlo simülasyonunu kullanır. Ancak tamamen rastgele sayılar (Pseudo-random) üretmek yerine, uzayı daha düzgün ve homojen tarayan **Halton Dizileri (Halton Sequences)** gibi "Yarı-Rastgele (Quasi-Random)" sayı dizileri kullanır. Bu sayede 10.000 MCMC iterasyonu yerine, sadece birkaç yüz Halton çekimi ile devasa integraller yüksek hassasiyetle hesaplanır ve optimizasyon algoritmaları (örneğin BFGS) çalıştırılabilir.

[!IMPORTANT] Özet: Müşteri churn ve yaşam boyu değerini hesaplarken, teorik formüller (Pareto/NBD, BG/BB) için sadece "tasarım" (mimari)

boyutudur. İşletmelerin bu tasarımları canlı sistemlere (Python/R) entegre edip devasa veritabanlarında çözebilmesi; Monte Carlo, MCMC, Gibbs Sampling ve Hiyerarşik Bayes gibi stokastik optimizasyon algoritmalarına borçludur. Olasılık modelleri MCMC'nin hesaplama gücüyle birleştğinde, churn tahmini bir sanattan tam teşekküllü bir mühendislik disiplinine dönüşür.